2교시 · 데이터프레임 다루기 I

주요 함수, 인덱싱과 슬라이싱

> 내용: 데이터 불러오기, 구조 파악 함수, 결측 코드 정리, `[행, 열]` 인덱싱 · 슬라이싱, 조건 선택, 정렬, 열 수정

이번 시간에 할 일

1. 데이터를 불러와서 **어떻게 생겼는지 파악**하기
2. 숨어 있는 **결측 코드** 찾아서 정리하기
3. 원하는 **행과 열만 골라내기** — `df[행, 열]`
4. 조건에 맞는 행 고르기, 정렬하기
5. 열 추가 · 수정 · 삭제

실제 분석도 이 순서(불러오기 → 살펴보기 → 정리 → 가공)로 진행함. 이 시간은 R에 기본으로 들어 있는 문법(base R)만 사용하며, 오후에 배울 dplyr도 결국 같은 작업을 다른 문법으로 하는 것이어서 여기서 익힌 개념이 그대로 이어짐.

데이터 불러오기

실습 데이터 준비

```
source("data/practice_data.R")
```

객체	행 수	내용
`fitness`	30	체력측정 원자료 (성인 22건 + 어르신 8건)
`programs`	15	측정 후 운동처방 프로그램 참여 기록 (5·6교시)

`source()`는 R 스크립트 파일을 통째로 실행하는 함수임. `practice_data.R` 안에 데이터를 만드는 코드가 들어 있어서, 실행하면 Environment 창에 두 데이터프레임이 생김. 국민체력100 측정 자료와 비슷한 구조로 만든 가상 데이터이며, 1교시에 직접 만든 `member`는 `fitness`의 앞 10명과 같음.

파일에서 불러오기

```
fitness_csv <- read.csv("data/fitness.csv")
dim(fitness_csv)
```

```
[1] 30 17
```

파일 형식	함수	패키지
CSV	`read.csv("파일.csv")`	기본 R
엑셀	`read_excel("파일.xlsx", sheet = 1)`	readxl
SPSS	`read_sav("파일.sav")`	haven
SAS / Stata	`read_sas()`, `read_dta()`	haven

> ⚠ 한글 깨짐
>
> Windows에서 엑셀로 저장한 CSV는 인코딩이 CP949인 경우가 많음. 한글이 깨지면 `read.csv("파일.csv", fileEncoding = "CP949")` 또는 `fileEncoding = "UTF-8"`을 지정해서 다시 불러옴. 공공데이터포털 등에서 내려받은 CSV도 인코딩을 먼저 확인하는 것이 좋음.

경로는 프로젝트 폴더 기준의 상대경로로 씀. `data/fitness.csv`는 "프로젝트 폴더 안의 data 폴더 안의 fitness.csv"라는 뜻임. 현재 작업 디렉토리는 `getwd()`로 확인할 수 있음.

구조 파악 함수

처음 받은 데이터에서 가장 먼저 하는 일

크기와 이름

```
dim(fitness)
```

```
[1] 30 17
```

```
nrow(fitness)
```

```
[1] 30
```

```
ncol(fitness)
```

```
[1] 17
```

```
names(fitness)
```

```
 [1] "id"          "stage"       "sex"         "age"         "center"
 [6] "region"      "exercise"    "height"      "weight"      "fat_pct"
[11] "grip"        "situp"       "sit_reach"   "shuttle"     "chair_stand"
[16] "walk_2min"   "grade"
```

`dim()`은 (행 수, 열 수)를 함께 돌려줌. `names()`와 `colnames()`는 같은 결과를 줌. 열 이름은 이후 모든 작업에서 계속 쓰므로 철자를 정확히 확인해 두는 것이 좋음.

열	내용	국민체력100 항목
`id`	측정 번호 (A: 성인, E: 어르신)	
`stage`	연령 단계 (성인 / 어르신)	
`sex`, `age`	성별, 나이	
`center`, `region`	측정 센터, 센터 지역	
`exercise`	운동 빈도	
`height`, `weight`	키(cm), 몸무게(kg)	신체조성(BMI)
`fat_pct`	체지방률(%)	신체조성
`grip`	악력(kg)	근력(상대악력)
`situp`	교차윗몸일으키기(회) — 성인만	근지구력
`sit_reach`	앉아윗몸앞으로굽히기(cm)	유연성
`shuttle`	20m 왕복오래달리기(회) — 성인만	심폐지구력
`chair_stand`	의자에앉았다일어서기(회) — 어르신만	근기능
`walk_2min`	2분제자리걷기(회) — 어르신만	심폐지구력
`grade`	인증 등급 (1~6등급)	

앞부분 · 뒷부분 보기

```
head(fitness)        # 앞 6행
```

```
   id stage sex age center region    exercise height weight fat_pct grip situp
1 A01  성인   M  50   가람   서울    주 1~2회  167.7   70.5    21.1 42.1    38
2 A02  성인   F  59   누리   경기 주 1회 미만  155.3   56.6    32.9 21.7    20
3 A03  성인   M  57   다온   부산    주 1~2회  173.9   71.8    16.3 41.4    34
4 A04  성인   F  47   라온   대전 주 1회 미만  165.3   53.0    32.9 25.9    18
5 A05  성인   M  51   가람   서울 주 3회 이상  163.7   79.0    19.1 45.2    52
6 A06  성인   F  48   누리   경기    주 1~2회  163.4   56.9    32.9 29.1    21
  sit_reach shuttle chair_stand walk_2min grade
1       4.4      34          NA        NA 4등급
2       5.2      13          NA        NA 2등급
3       7.9      32          NA        NA 3등급
4      10.6      17          NA        NA 5등급
5      14.2      47          NA        NA 1등급
6      13.6      20          NA        NA 3등급
```

```r
tail(fitness, 3)     # 뒤 3행
```

```
    id  stage sex age center region    exercise height weight fat_pct grip
28 E06 어르신   F  79   라온   대전 주 3회 이상  152.0   63.7    30.8 19.3
29 E07 어르신   F  76   가람   서울    주 1~2회  150.7   53.5    32.6 23.6
30 E08 어르신   F  72   누리   경기    주 1~2회  152.3   52.2    29.0 22.1
   situp sit_reach shuttle chair_stand walk_2min    grade
28    NA       2.7      NA          18       104    2등급
29    NA      12.3      NA          15        94 측정중단
30    NA      15.0      NA          16       106    4등급
```

- 열이 많으면 화면 폭에 맞춰 여러 줄로 나뉘어 출력됨
- `View(fitness)` → 엑셀처럼 생긴 별도 창에서 보기 (정렬 · 검색 가능)

구조 `str()`

```r
str(fitness)
```

```
'data.frame':   30 obs. of  17 variables:
 $ id         : chr  "A01" "A02" "A03" "A04" ...
 $ stage      : chr  "성인" "성인" "성인" "성인" ...
 $ sex        : chr  "M" "F" "M" "F" ...
 $ age        : num  50 59 57 47 51 48 36 31 46 45 ...
 $ center     : chr  "가람" "누리" "다온" "라온" ...
 $ region     : chr  "서울" "경기" "부산" "대전" ...
 $ exercise   : chr  "주 1~2회" "주 1회 미만" "주 1~2회" "주 1회 미만" ...
 $ height     : num  168 155 174 165 164 ...
 $ weight     : num  70.5 56.6 71.8 53 79 56.9 84.7 53 84.5 47.8 ...
 $ fat_pct    : num  21.1 32.9 16.3 32.9 19.1 32.9 19 26.6 24.1 29.2 ...
 $ grip       : num  42.1 21.7 41.4 25.9 45.2 29.1 41.9 34 43.2 21.8 ...
 $ situp      : num  38 20 34 18 52 21 41 34 38 14 ...
 $ sit_reach  : num  4.4 5.2 7.9 10.6 14.2 13.6 -0.2 15.6 6.1 10.4 ...
 $ shuttle    : num  34 13 32 17 47 20 43 41 47 24 ...
 $ chair_stand: num  NA NA NA NA NA NA NA NA NA NA ...
 $ walk_2min  : num  NA NA NA NA NA NA NA NA NA NA ...
 $ grade      : chr  "4등급" "2등급" "3등급" "5등급" ...
```

`'data.frame': 30 obs. of 17 variables`는 30행 17열이라는 뜻임. 각 열의 자료형과 처음 몇 개의 값을 보여줌. 숫자여야 할 측정값 열이 `chr`(문자)로 나오면 문자가 섞여 있다는 신호임. `chair_stand`, `walk_2min`의 처음 값이 `NA`인 이유는 성인에게는 측정하지 않는 항목이기 때문임.

요약 `summary()` — 이상한 값 찾기

```r
summary(fitness$age)
```

```
    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   -9.00   38.00   49.00   81.30   65.75  999.00
```

```r
summary(fitness$grip)
```

```
    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   -1.00   23.23   29.25   62.00   40.35  999.00
```

```r
summary(fitness$shuttle)
```

```
    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NA's
   -1.00   19.00   26.00   29.00   41.75   55.00       8
```

- 나이 최솟값 `-9`, 최댓값 `999`?
- 악력 최댓값 `999`kg, 최솟값 `-1`kg?
- 왕복오래달리기 `-1`회? `NA's: 8`은 어르신 8명

`summary()`는 숫자형 열의 최솟값, 1사분위수, 중앙값, 평균, 3사분위수, 최댓값과 결측 개수(`NA's`)를 보여줌. 최솟값이 음수이거나 최댓값이 비정상적으로 크면 결측 코드나 입력 오류를 의심해야 함. `summary(fitness)`로 모든 열을 한 번에 볼 수도 있음.

범주형 열 살펴보기

```
table(fitness$stage)
```

```
   성인 어르신
     22      8
```

```
table(fitness$sex)
```

```
    F     M 미상
   15    14     1
```

```
table(fitness$exercise)
```

```
                주 1~2회 주 1회 미만 주 3회 이상
          1           14           8           7
```

```
table(fitness$grade)
```

```
    1등급     2등급     3등급     4등급     5등급     6등급 측정중단
       6         6         3         6         5         3         1
```

성별 `"미상"`, 운동 빈도 `""`(빈 칸), 등급 `"측정중단"`도 결측

구조 파악 함수 정리

함수	하는 일	함수	하는 일
`dim()`	행 수, 열 수	`str()`	열별 자료형과 값 미리보기
`nrow()` / `ncol()`	행 수 / 열 수	`summary()`	열별 요약통계
`names()`	열 이름	`table()`	값별 빈도
`head()` / `tail()`	앞 / 뒤 몇 행	`unique()`	중복 없는 값 목록
`View()`	표 형태로 보기	`prop.table()`	빈도를 비율로

데이터를 받으면 `dim()` → `str()` → `summary()` · `table()` 순서로 한 번씩 돌려 보는 습관을 들이면 대부분의 문제를 초기에 발견할 수 있음

결측 코드 정리

두 종류의 결측

```
sum(is.na(fitness))
```

```
[1] 60
```

```
colSums(is.na(fitness))
```

```
        id      stage        sex        age     center     region 
         0          0          0          0          0          0 
  exercise     height     weight    fat_pct       grip      situp 
         0          0          0          0          0          8 
 sit_reach    shuttle chair_stand  walk_2min      grade 
         0          8         22         22          0 
```

종류	예	R이 알아보는가
진짜 `NA`	성인의 `chair_stand`, 어르신의 `shuttle`	O
결측 코드	`-9`, `999`, `-1`, `"미상"`, `""`, `"측정중단"`	**X**

`is.na()`는 R이 진짜 `NA`로 저장한 값만 찾아냄. 여기서 잡힌 60개는 모두 "해당 연령 단계에서 측정하지 않는 항목"임. 측정 거부나 입력 오류를 뜻하는 `-9`, `999` 같은 코드는 R 입장에서는 정상적인 숫자이므로 `is.na()`로 찾을 수 없고, 그대로 두면 평균 등이 왜곡됨. 어떤 값이 결측 코드인지는 반드시 코드북(자료 설명서)에서 확인해야 함.

결측 코드를 NA로 바꾸기

```
fit <- fitness                                    # 원자료는 그대로 두고 복사본에서 작업
fit$age[fit$age %in% c(-9, 999)]     <- NA
fit$grip[fit$grip %in% c(-1, 999)]   <- NA
fit$shuttle[fit$shuttle == -1]       <- NA
fit$sex[fit$sex == "미상"]           <- NA
fit$exercise[fit$exercise == ""]     <- NA
fit$grade[fit$grade == "측정중단"]   <- NA

colSums(is.na(fit))
```

```
        id       stage         sex         age      center      region
         0           0           1           2           0           0
  exercise      height      weight     fat_pct        grip       situp
         1           0           0           0           2           8
 sit_reach     shuttle chair_stand   walk_2min       grade
         0           9          22          22           1
```

`fit$age[조건] <- NA`는 "age 열에서 조건이 TRUE인 위치에 NA를 넣어라"라는 뜻으로, 1교시 벡터 조건 인덱싱(`grip[grip > 40]`)에 값을 넣는 방식임. 원자료(`fitness`)를 보존하기 위해 복사본(`fit`)에서 작업함. 이후 실습은 모두 정리된 `fit`을 사용함.

정리 전후 비교

```
mean(fitness$grip)              # 결측 코드 그대로: 왜곡
```

```
[1] 62.00333
```

```
mean(fit$grip)                  # NA가 있으면 NA
```

```
[1] NA
```

```
mean(fit$grip, na.rm = TRUE)    # NA 빼고 계산
```

```
[1] 30.78929
```

```
summary(fit$age)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NA's
  25.00   42.00   49.00   51.75   65.25   79.00       2
```

> ⚠️ 조심
>
> `na.rm = TRUE`는 결측을 빼고 계산하라는 뜻임. `fit`에는 측정하지 않는 항목(연령 단계별)과 결측 코드에서 바뀐 `NA`가 함께 있으므로, 평균을 구할 때 `na.rm = TRUE`가 자주 필요함. `na.omit(fit)`은 어느 열이든 결측이 하나라도 있는 행을 통째로 지우는데, 이 데이터에서는 모든 행에 해당 없는 항목의 `NA`가 있어서 0행이 됨. 필요한 열만 고른 뒤에 적용해야 함.

인덱싱과 슬라이싱

`df[행, 열]`

$로 열 하나 꺼내기

```
fit$grip
```

```
 [1] 42.1 21.7 41.4 25.9 45.2 29.1 41.9 34.0 43.2 21.8 30.6 38.7 40.9   NA 26.6
[16] 35.8 22.2 24.3 49.5   NA 23.1 17.8 32.9 29.6 29.4 25.1 24.3 19.3 23.6 22.1
```

```
fit$center
```

```
 [1] "가람" "누리" "다온" "라온" "가람" "누리" "다온" "라온" "가람" "누리"
[11] "다온" "라온" "가람" "누리" "다온" "라온" "가람" "누리" "다온" "라온"
[21] "가람" "누리" "다온" "라온" "가람" "누리" "다온" "라온" "가람" "누리"
```

```
class(fit$grip)
```

```
[1] "numeric"
```

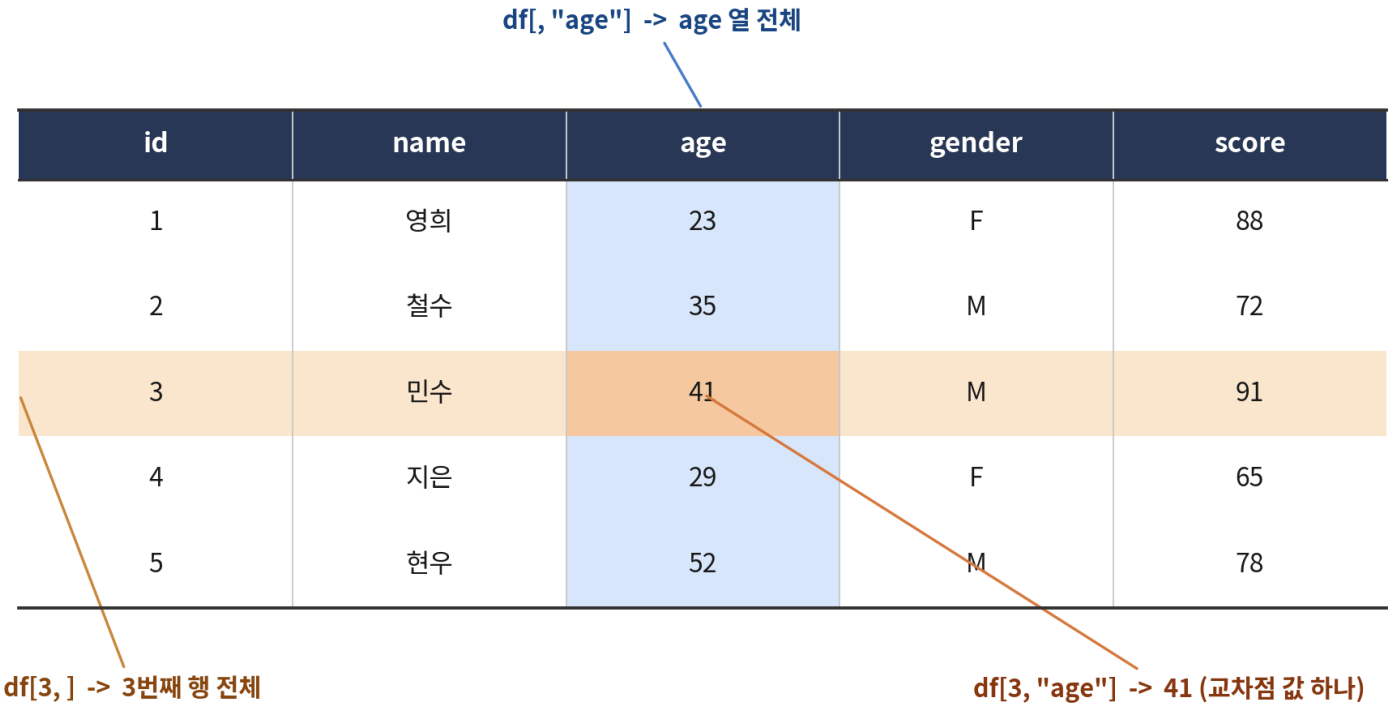
```
mean(fit$grip, na.rm = TRUE)
```

```
[1] 30.78929
```

- `df$열이름` → 열 하나를 **벡터**로 꺼냄
- RStudio에서 `fit$`까지 치면 열 이름 자동완성

`df[행, 열]` 기본 문법

df[행, 열] 인덱싱 예시 (일부 5행만 표시)



id	name	age	gender	score
1	영희	23	F	88
2	철수	35	M	72
3	민수	41	M	91
4	지은	29	F	65
5	현우	52	M	78

- 대괄호 안을 콤마로 나눔
- 콤마 **앞 = 행**, 콤마 **뒤 = 열**
- 비워두면 **전체**
- 번호, 이름, 조건(TRUE/FALSE) 모두 가능

행 · 열 · 셀 선택

▶ **행**

```
fit[3, ]          # 3행 전체
```

```
   id stage sex age center region exercise height weight fat_pct grip situp
3 A03  성인   M  57   다온   부산 주 1~2회  173.9   71.8    16.3 41.4    34
  sit_reach shuttle chair_stand walk_2min grade
3       7.9      32          NA        NA 3등급
```

```
fit[c(1, 23), ]    # 1행과 23행 (성인 1명, 어르신 1명)
```

```
    id  stage sex age center region    exercise height weight fat_pct grip
1  A01   성인   M  50   가람   서울     주 1~2회  167.7   70.5    21.1 42.1
23 E01 어르신   M  71   다온   부산 주 3회 이상  176.1   55.7    26.4 32.9
   situp sit_reach shuttle chair_stand walk_2min grade
1     38       4.4      34          NA        NA 4등급
23    NA       4.1      NA          13       103 2등급
```

▶ **열**

```
fit[, 11]          # 11번째 열 → 벡터
```

```
 [1] 42.1 21.7 41.4 25.9 45.2 29.1 41.9 34.0 43.2 21.8 30.6 38.7 40.9   NA 26.6
[16] 35.8 22.2 24.3 49.5   NA 23.1 17.8 32.9 29.6 29.4 25.1 24.3 19.3 23.6 22.1
```

```
fit[, "grip"]      # 이름으로 → 벡터
```

```
 [1] 42.1 21.7 41.4 25.9 45.2 29.1 41.9 34.0 43.2 21.8 30.6 38.7 40.9   NA 26.6
[16] 35.8 22.2 24.3 49.5   NA 23.1 17.8 32.9 29.6 29.4 25.1 24.3 19.3 23.6 22.1
```

▶ **행과 열**

```
fit[3, "grip"]                    # 셀 하나
```

```
[1] 41.4
```

```
fit[c(1, 23), c("id", "stage", "grip")]
```

```
    id  stage grip
1  A01   성인 42.1
23 E01 어르신 32.9
```

⚠ 확인

`fit[3, ]`(3행 전체)와 `fit[, 3]`(3열 전체)은 완전히 다른 결과임. 콤마 위치를 항상 확인해야 함.

슬라이싱: 범위로 자르기

```
fit[1:3, 1:6]
```

```
   id stage sex age center region
1 A01  성인   M  50   가람   서울
2 A02  성인   F  59   누리   경기
3 A03  성인   M  57   다온   부산
```

```
fit[21:24, c("id", "stage", "age", "situp", "chair_stand")]
```

```
    id  stage age situp chair_stand
21 A21   성인  26    22          NA
22 A22   성인  55     9          NA
23 E01 어르신  71    NA          13
24 E02 어르신  65    NA          13
```

```
fit[-(1:27), c("id", "age", "grip")]
```

```
    id age grip
28 E06  79 19.3
29 E07  76 23.6
30 E08  72 22.1
```

`1:3` 처럼 범위를 주면 연속된 행·열을 잘라냄(슬라이싱). 두 번째 줄은 성인과 어르신의 경계(22행과 23행)를 잘라 본 것으로, 해당 없는 항목이 `NA` 인 것을 확인할 수 있음. 음수는 해당 위치를 빼라는 뜻이어서 `fit[-(1:27), ]` 은 1~27행을 뺀 나머지(28~30행)가 됨. `-1:27` 이라고 쓰면 `-1, 0, 1, …, 27` 로 해석되어 오류가 나므로 괄호가 필요함.

여러 열 선택

```
head(fit[, c("id", "sex", "age", "height", "weight")])
```

```
   id sex age height weight
1 A01   M  50  167.7   70.5
2 A02   F  59  155.3   56.6
3 A03   M  57  173.9   71.8
4 A04   F  47  165.3   53.0
5 A05   M  51  163.7   79.0
6 A06   F  48  163.4   56.9
```

```
head(fit[, -(7:17)])
```

```
   id stage sex age center region
1 A01  성인   M  50   가람   서울
2 A02  성인   F  59   누리   경기
3 A03  성인   M  57   다온   부산
4 A04  성인   F  47   라온   대전
5 A05  성인   M  51   가람   서울
6 A06  성인   F  48   누리   경기
```

열 번호로 고르면 데이터 구조가 바뀌었을 때(열이 추가·삭제되었을 때) 엉뚱한 열이 선택될 수 있음. 가능하면 열 이름으로 고르는 것이 안전함. `head()` 로 감싸면 앞 6행만 보여줌.

열 하나만 고르면 벡터가 됨

```
class(fit[, "grip"])
```

```
[1] "numeric"
```

```
class(fit[, c("id", "grip")])
```

```
[1] "data.frame"
```

```
fit[1:3, "grip", drop = FALSE]
```

```
  grip
1 42.1
2 21.7
3 41.4
```

```
class(fit["grip"])
```

```
[1] "data.frame"
```

> ⓘ 참고
>
> 열을 **하나만** 고르면 R이 자동으로 벡터로 바꿈. 데이터프레임 모양을 유지하려면 `drop = FALSE`를 쓰거나 콤마 없이 `fit["grip"]`처럼 씀

조건으로 행 고르기

조건 → TRUE/FALSE → 행 선택

```
fit$stage == "어르신"
```

```
 [1] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE
[13] FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE FALSE  TRUE  TRUE
[25]  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
```

```
fit[fit$stage == "어르신", c("id", "age", "grip", "chair_stand")]
```

```
    id age grip chair_stand
23 E01  71 32.9          13
24 E02  65 29.6          13
25 E03  71 29.4          12
26 E04  79 25.1          10
27 E05  66 24.3          16
28 E06  79 19.3          18
29 E07  76 23.6          15
30 E08  72 22.1          16
```

조건식은 행 수만큼의 TRUE/FALSE 벡터를 만들고, 이 벡터를 콤마 앞(행 자리)에 넣으면 TRUE인 행만 남음. 1교시 벡터 인덱싱 `grip[grip > 40]`과 같은 원리임. 콤마 뒤에 열 이름을 넣으면 행과 열을 동시에 고를 수 있음.

여러 조건 결합

▸ 그리고 &

```r
# 성인이면서 남성
fit[fit$stage == "성인" & fit$sex == "M", c("id", "sex", "age", "grip")]
```

```
     id  sex age grip
1   A01    M  50 42.1
3   A03    M  57 41.4
5   A05    M  51 45.2
7   A07    M  36 41.9
9   A09    M  46 43.2
12  A12    M  NA 38.7
13  A13    M  25 40.9
16  A16    M  61 35.8
NA <NA> <NA>  NA   NA
19  A19    M  34 49.5
20  A20    M  46   NA
```

▸ 또는 |

```r
# 주 3회 이상 운동하거나 1등급
fit[fit$exercise == "주 3회 이상" | fit$grade == "1등급", c("id", "exercise", "grade")]
```

```
       id    exercise grade
5     A05 주 3회 이상 1등급
8     A08 주 3회 이상 1등급
11    A11    주 1~2회 1등급
14    A14 주 3회 이상 2등급
19    A19 주 3회 이상 1등급
NA   <NA>        <NA>  <NA>
23    E01 주 3회 이상 2등급
24    E02    주 1~2회 1등급
27    E05 주 3회 이상 1등급
28    E06 주 3회 이상 2등급
NA.1 <NA>        <NA>  <NA>
```

▶ **여러 값 중 하나 %in%**

```r
fit[fit$center %in% c("가람", "다온"), c("id", "center", "region")]
```

```
    id center region
1  A01   가람   서울
3  A03   다온   부산
5  A05   가람   서울
7  A07   다온   부산
9  A09   가람   서울
11 A11   다온   부산
13 A13   가람   서울
15 A15   다온   부산
17 A17   가람   서울
19 A19   다온   부산
21 A21   가람   서울
23 E01   다온   부산
25 E03   가람   서울
27 E05   다온   부산
29 E07   가람   서울
```

| 결과에 `NA`로만 채워진 행이 보이면, 조건 계산에 쓰인 열(`exercise`, `grade`)에 `NA`가 있기 때문임. 다음 슬라이드에서 다룸.

조건에 `NA`가 있으면

```r
fit[fit$grip >= 40, c("id", "sex", "grip")]
```

```
       id  sex grip
1     A01    M 42.1
3     A03    M 41.4
5     A05    M 45.2
7     A07    M 41.9
9     A09    M 43.2
13    A13    M 40.9
NA   <NA> <NA>   NA
19    A19    M 49.5
NA.1 <NA> <NA>   NA
```

`which()` · `subset()` 로 해결

```r
fit[which(fit$grip >= 40), c("id", "sex", "grip")]
```

```
    id sex grip
1  A01   M 42.1
3  A03   M 41.4
5  A05   M 45.2
7  A07   M 41.9
9  A09   M 43.2
13 A13   M 40.9
19 A19   M 49.5
```

```r
subset(fit, grip >= 40, select = c(id, sex, grip))
```

```
    id sex grip
1  A01   M 42.1
3  A03   M 41.4
5  A05   M 45.2
7  A07   M 41.9
9  A09   M 43.2
13 A13   M 40.9
19 A19   M 49.5
```

악력이 `NA` 인 행은 조건 결과도 `NA` 가 되어, 대괄호 인덱싱에서는 모든 값이 `NA` 인 행으로 나타남. `which()` 로 TRUE인 위치만 뽑거나 `subset()` 을 쓰면 `NA` 행이 빠짐. 오후에 배울 dplyr `filter()` 도 `NA` 행을 자동으로 뺌.

조건에 맞는 개수 · 위치

```r
sum(fit$stage == "어르신")          # 몇 명?
```

```
[1] 8
```

```r
mean(fit$exercise == "주 3회 이상", na.rm = TRUE)   # 비율
```

```
[1] 0.2413793
```

```r
which(fit$grade == "1등급")          # 몇 번째 행?
```

```
[1]  5  8 11 19 24 27
```

```r
fit$id[which(fit$grade == "1등급")]  # 1등급 측정 번호
```

```
[1] "A05" "A08" "A11" "A19" "E02" "E05"
```

```r
mean(fit$grip[fit$sex == "F"], na.rm = TRUE)
```

```
[1] 24.43571
```

마지막 줄은 "여성 측정자의 악력 벡터"를 먼저 꺼낸 뒤 평균을 구한 것임. 성별·연령 단계별 평균을 구할 때 이렇게 쓰면 집단 수만큼 코드를 반복해야 하는데, 오후에 배울 `group_by()` + `summarize()`로 한 번에 해결할 수 있음.

정렬

`order()`로 정렬

```r
order(fit$grip)
```

```
 [1] 22 28  2 10 30 17 21 29 18 27 26  4 15  6 25 24 11 23  8 16 12 13  3  7  1
[26]  9  5 19 14 20
```

```r
head(fit[order(fit$grip), c("id", "sex", "grip")])
```

```
    id sex grip
22 A22   F 17.8
28 E06   F 19.3
2  A02   F 21.7
10 A10   F 21.8
30 E08   F 22.1
17 A17   F 22.2
```

- `order()`는 정렬된 값이 아니라 **정렬 순서(행 번호)**를 돌려줌
- 이 순서를 행 자리에 넣으면 정렬된 데이터프레임
- `NA`는 맨 뒤로 감

내림차순 · 여러 기준

```r
# 악력 내림차순
head(fit[order(fit$grip, decreasing = TRUE), c("id", "sex", "grip")])
```

```
    id sex grip
19 A19   M 49.5
5  A05   M 45.2
9  A09   M 43.2
1  A01   M 42.1
7  A07   M 41.9
3  A03   M 41.4
```

```r
# 연령 단계로 묶고, 그 안에서 앉아윗몸앞으로굽히기 내림차순
fit[order(fit$stage, -fit$sit_reach), c("id", "stage", "sit_reach")]
```

```
    id  stage sit_reach
17 A17   성인      17.2
18 A18   성인      16.7
11 A11   성인      15.7
8  A08   성인      15.6
19 A19   성인      15.0
5  A05   성인      14.2
6  A06   성인      13.6
15 A15   성인      12.5
14 A14   성인      12.0
4  A04   성인      10.6
10 A10   성인      10.4
13 A13   성인       9.0
3  A03   성인       7.9
21 A21   성인       6.7
9  A09   성인       6.1
2  A02   성인       5.2
1  A01   성인       4.4
22 A22   성인       3.9
20 A20   성인       3.4
16 A16   성인       1.8
7  A07   성인      -0.2
12 A12   성인      -3.4
30 E08 어르신      15.0
27 E05 어르신      13.5
29 E07 어르신      12.3
23 E01 어르신       4.1
28 E06 어르신       2.7
24 E02 어르신       1.5
25 E03 어르신      -0.6
26 E04 어르신      -1.7
```

> ⚠ 주의
>
> 정렬 결과를 저장하지 않으면 원본 `fit`은 그대로임. 정렬된 상태를 계속 쓰려면 `fit_sorted <- fit[order(fit$grip), ]`처럼 새 객체에 저장함. 숫자 열 앞의 `-`는 내림차순을 뜻하며 문자 열에는 쓸 수 없음.

열 추가 · 수정 · 삭제

새 열 만들기

```r
fit$bmi      <- round(fit$weight / (fit$height / 100)^2, 1)   # BMI
fit$grip_rel <- round(fit$grip / fit$weight * 100, 1)          # 상대악력(%)
fit$active   <- fit$exercise == "주 3회 이상"                  # 논리형
head(fit[, c("id", "bmi", "grip", "grip_rel", "exercise", "active")])
```

```
   id  bmi grip grip_rel    exercise active
1 A01 25.1 42.1     59.7    주 1~2회  FALSE
2 A02 23.5 21.7     38.3 주 1회 미만  FALSE
3 A03 23.7 41.4     57.7    주 1~2회  FALSE
4 A04 19.4 25.9     48.9 주 1회 미만  FALSE
5 A05 29.5 45.2     57.2 주 3회 이상   TRUE
6 A06 21.3 29.1     51.1    주 1~2회  FALSE
```

`df$새열이름 <- 값` 형태로 쓰면 열이 추가됨. 이미 있는 열 이름을 쓰면 그 열이 덮어써짐. 열끼리의 계산은 같은 행끼리 이루어지므로(1교시 벡터 연산), 측정자마다 BMI와 상대악력이 한 번에 계산됨.

조건으로 값 나누기 — `ifelse()` · `cut()`

```
fit$bmi_grp <- ifelse(fit$bmi < 18.5, "저체중",
               ifelse(fit$bmi < 23,   "정상",
               ifelse(fit$bmi < 25,   "과체중", "비만")))
table(fit$bmi_grp)
```

```
 과체중    비만 저체중    정상
      4      12       2      12
```

```
fit$age_grp <- cut(fit$age,
                   breaks = c(18, 39, 64, Inf),
                   labels = c("19~39세", "40~64세", "65세 이상"))
table(fit$age_grp, useNA = "ifany")
```

```
   19~39세    40~64세 65세 이상       <NA>
         7         13          8          2
```

`ifelse(조건, 참일 때 값, 거짓일 때 값)`을 겹쳐 쓰면 여러 구간으로 나눌 수 있음. 18.5 / 23 / 25는 아시아-태평양 기준 BMI 구간임. `cut()`은 숫자를 구간으로 나누는 함수로, `breaks`는 구간 경계임(`c(18, 39, 64, Inf)`는 (18, 39], (39, 64], (64, ∞) 세 구간). `cut()`의 결과는 팩터이므로 순서가 자동으로 유지됨. `useNA = "ifany"`는 `NA`도 빈도표에 함께 보여달라는 뜻임(나이가 결측인 2명). 오후에는 같은 작업을 `case_when()`으로 더 읽기 쉽게 함.

값 수정 · 이름 변경 · 열 삭제

```r
# 특정 셀 값 수정 (재측정 결과 반영)
fit[3, "grip"] <- 41.8

# 열 이름 바꾸기
names(fit)[names(fit) == "fat_pct"] <- "fat"

# 열 삭제 (NULL 할당)
fit$active <- NULL
names(fit)
```

```
 [1] "id"          "stage"       "sex"         "age"         "center"
 [6] "region"      "exercise"    "height"      "weight"      "fat"
[11] "grip"        "situp"       "sit_reach"   "shuttle"     "chair_stand"
[16] "walk_2min"   "grade"       "bmi"         "grip_rel"    "bmi_grp"
[21] "age_grp"
```

`names(fit) == "fat_pct"`는 열 이름 중 `"fat_pct"` 위치만 TRUE인 논리 벡터이고, 그 자리의 이름만 새 이름으로 바꾸는 방식임. 오후에 배울 `rename()`을 쓰면 `rename(fit, fat = fat_pct)`로 간단해짐.

정리

작업	base R 문법
구조 파악	`dim()`, `str()`, `summary()`, `table()`
결측 코드 → NA	`df$col[df$col %in% c(-9, 999)] <- NA`
열 하나	`df$col`, `df[, "col"]`, `df[["col"]]`
행 · 열 선택	`df[행, 열]`, `df[1:3, c("a", "b")]`
조건으로 행 선택	`df[which(df$age >= 40), ]`, `subset(df, age >= 40)`
정렬	`df[order(df$col), ]`, `order(-df$col)`
새 열	`df$new <- 계산식`, `ifelse()`, `cut()`
열 삭제 · 이름 변경	`df$col <- NULL`, `names(df)[...] <- "new"`

실습 · 체력측정 데이터

`fitness`를 다시 정리한 `fit` 사용 (결측 코드 정리 슬라이드의 코드를 한 번 더 실행)

1. 연령 단계(`stage`)별, 센터(`center`)별 인원 구하기
2. 1등급 · 2등급인 사람의 비율 구하기
3. 성인 중 왕복오래달리기(`shuttle`) 40회 이상인 사람의 `id`, `sex`, `age`, `shuttle`을 `shuttle` 내림차순으로 보기
4. 남성의 평균 악력과 여성의 평균 악력 구하기
5. 어르신의 의자에앉았다일어서기(`chair_stand`) 평균과, 성인의 교차윗몸일으키기(`situp`) 평균 구하기