제1장 자료의 특성과 기술통계

자료 분석에서는 먼저 각 변수가 무엇을 나타내는지 파악하고, 관측값의 분포를 요약하는 과정이 필요합니다. **기술통계(descriptive statistics)**는 수치와 그래프를 이용하여 자료의 중심, 산포, 형태를 설명하는 방법입니다. 평균이 같더라도 관측값의 퍼짐은 다를 수 있으며, 같은 표준편차도 평균의 크기에 따라 다른 의미를 가질 수 있습니다.

이 장에서는 자료와 변수의 유형을 구분하고, 평균·중앙값·분산·표준편차·변동계수 등의 개념과 R 계산 방법을 살펴봅니다. 이어서 변수 유형에 적합한 도표를 R의 기본 그래픽 함수로 작성합니다. 이 장의 실습에는 별도 패키지 설치가 필요하지 않습니다.

1.1 자료의 구조와 변수의 유형

1.1.1 정형자료

정형자료는 행과 열로 정리할 수 있는 자료입니다. 일반적으로 행은 관측 대상 한 명 또는 측정 한 건을, 열은 그 대상에서 측정한 변수를 나타냅니다. 엑셀 표, CSV 파일, R의 데이터프레임이 대표적인 형태입니다.

1.1.2 범주형 변수와 수치형 변수

변수의 유형은 저장된 값의 모양뿐 아니라 **그 값이 갖는 의미**에 따라 판단합니다. 예를 들어 집단을 1과 2로 기록하더라도 두 값이 집단의 이름을 나타낸다면 수치의 평균은 의미가 없습니다.

구분	의미	스포츠 분야의 예	주로 사용하는 요약
명목형 범주	범주 사이에 순서가 없음	운동 종목, 프로그램 집단	도수, 비율, 최빈범주
순서형 범주	범주 사이에 순서가 있음	만족도, 체력 등급	도수, 비율, 순서에 따른 분포
이산형 수치	가능한 값을 하나씩 셀 수 있음	주간 운동 횟수, 성공 횟수	도수, 평균, 분산
연속형 수치	일정 구간에서 연속적인 값을 가짐	키, 체중, 악력, 반응시간	평균, 중앙값, 표준편차, 분위수

1.1.3 R의 factor와 numeric

`factor`는 R에서 **범주형 자료를 표현하는 자료형**입니다. 범주의 이름과 가능한 수준(`levels`)을 함께 저장합니다. 이산형 확률변수를 뜻하는 통계 용어와는 구분됩니다. 횟수는 이산형이지만 평균을 계산할 때는 숫자로 저장하고, 범주별 도수를 표시할 때만 필요에 따라 factor로 변환할 수 있습니다.

```
event <- factor(c("달리기", "수영", "달리기", "근력운동"))
levels(event)
```

```
[1] "근력운동" "달리기"   "수영"
```

```
table(event)
```

```
event
근력운동    달리기      수영
       1         2         1
```

```r
satisfaction <- factor(
  c("보통", "높음", "낮음", "높음"),
  levels = c("낮음", "보통", "높음"),
  ordered = TRUE
)
satisfaction
```

```
[1] 보통 높음 낮음 높음
Levels: 낮음 < 보통 < 높음
```

```r
sessions <- c(1, 3, 2, 4, 2)  # 이산형 수치 자료
grip <- c(28.5, 32.1, 30.8)   # 연속형 측정 자료
mean(sessions)
```

```
[1] 2.4
```

```r
mean(grip)
```

```
[1] 30.46667
```

`ordered = TRUE`는 범주의 순서를 명시합니다. `mean()`은 숫자 자료의 평균을 계산하는 함수이며, 범주의 이름을 갖는 factor에는 적용하지 않습니다. 특히 `as.numeric(factor(...))`의 결과는 범주의 내부 코드이므로 원래 측정값으로 해석해서는 안 됩니다.

1.1.4 실습 자료

이후 실습에서는 운동 참여자 20명의 집단, 주간 운동 횟수, 악력, 점프 높이로 구성된 **가상 자료**를 사용합니다. 설명을 위한 자료이며 실제 집단의 특성이나 평가 기준을 나타내지 않습니다.

```r
fitness <- data.frame(
  id = 1:20,
  group = factor(rep(c("A", "B"), each = 10), levels = c("A", "B")),
  sessions = c(1, 2, 3, 2, 4, 3, 1, 2, 3, 4,
               2, 3, 4, 3, 5, 4, 2, 3, 4, 5),
  grip_kg = c(24, 28, 30, 31, 32, 33, 34, 36, 38, 42,
              27, 31, 33, 35, 36, 38, 40, 42, 46, 58),
  jump_cm = c(25, 28, 30, 29, 31, 32, 34, 33, 36, 38,
              26, 30, 31, 33, 35, 36, 38, 40, 43, 46)
)

head(fitness)
```

```
  id group sessions grip_kg jump_cm
1  1     A        1      24      25
2  2     A        2      28      28
3  3     A        3      30      30
4  4     A        2      31      29
5  5     A        4      32      31
6  6     A        3      33      32
```

```
str(fitness)
```

```
'data.frame':   20 obs. of  5 variables:
 $ id      : int  1 2 3 4 5 6 7 8 9 10 ...
 $ group   : Factor w/ 2 levels "A","B": 1 1 1 1 1 1 1 1 1 1 ...
 $ sessions: num  1 2 3 2 4 3 1 2 3 4 ...
 $ grip_kg : num  24 28 30 31 32 33 34 36 38 42 ...
 $ jump_cm : num  25 28 30 29 31 32 34 33 36 38 ...
```

`data.frame()`은 변수를 열로 결합하여 표를 만듭니다. `1:20`은 1부터 20까지의 정수, `rep(..., each = 10)`은 각 값을 10번씩 반복하는 표현입니다. `head()`는 앞의 6행을, `str()`은 자료의 구조와 각 변수의 자료형을 보여 줍니다. `fitness$grip_kg`처럼 `$`를 사용하면 데이터프레임에서 특정 열을 선택할 수 있습니다.

1.2 중심위치와 분위수

1.2.1 평균

산술평균(mean)은 관측값의 합을 관측 수로 나눈 값입니다. 크기가 n인 표본의 관측값을 $x_1, \ldots, x_n$이라 하면 표본평균은 다음과 같습니다.

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

관심 대상 전체를 **모집단**, 그중 일부를 관측한 자료를 **표본**이라고 합니다. 유한 모집단 전체 N개의 값을 알고 있다면 모집단 평균은 $\mu = \sum_{i=1}^{N} x_i / N$으로 계산합니다. 평균을 구하는 산술적 절차는 같지만, 전체를 요약하는지 표본을 요약하는지에 따라 해석이 달라집니다.

```
x <- c(20, 25, 30, 35, 40)

sum(x) / length(x)
```

```
[1] 30
```

```
mean(x)
```

```
[1] 30
```

```r
mean(fitness$grip_kg)
```

```
[1] 35.7
```

`sum()`은 합계, `length()`는 원소 수를 반환합니다. 예제 `x`의 평균은 30입니다. 평균은 모든 관측값을 반영하므로 대표값으로 널리 사용되지만, 극단적으로 큰 값이나 작은 값의 영향을 받습니다.

1.2.2 중앙값과 절사평균

중앙값(median)은 관측값을 크기순으로 정렬했을 때 가운데 위치한 값입니다. 관측 수가 홀수이면 가운데 한 값을 사용하고, 짝수이면 가운데 두 값의 평균을 사용합니다.

절사평균(trimmed mean)은 정렬한 자료의 양쪽 끝에서 일정 비율을 제외한 뒤 계산한 평균입니다. R에서 `mean(x, trim = 0.1)`은 **아래쪽과 위쪽에서 각각 10%**를 제외합니다. 제거할 관측 수는 각 방향에서 `floor(length(x) * 0.1)`개입니다. 따라서 관측 수가 적으면 지정한 비율에 따라 실제로 제거되는 값이 없을 수도 있습니다.

다음은 첨부 강의자료의 대표값 비교 예제를 R로 계산한 것입니다.

```r
data1 <- c(2, 2, 2, 3, 3, 3, 3, 4, 4, 5)
data2 <- c(1, 2, 2, 3, 3, 3, 5, 5, 7, 1000)

center_compare <- data.frame(
  data = c("자료1", "자료2"),
  mean = c(mean(data1), mean(data2)),
  median = c(median(data1), median(data2)),
  trimmed_mean = c(mean(data1, trim = 0.1), mean(data2, trim = 0.1))
)
center_compare
```

```
   data  mean median trimmed_mean
1 자료1   3.1      3         3.00
2 자료2 103.1      3         3.75
```

자료2의 평균은 103.1이지만 중앙값은 3, 10% 절사평균은 3.75입니다. 큰 관측값 1000이 평균에 미치는 영향을 확인할 수 있습니다. 분포가 비대칭이거나 극단값이 있는 경우에는 평균과 함께 중앙값, 절사평균을 검토합니다. 절사는 정의된 요약 방법이며, 극단값을 오류로 판단하여 삭제하는 과정과는 다릅니다.

1.2.3 최빈값

최빈값(mode)은 가장 자주 관측되는 값입니다. 범주형 자료에서는 최빈범주를 통해 가장 많은 관측이 속한 범주를 파악할 수 있습니다. 최빈값이 여러 개일 수 있으며, 모든 값의 빈도가 같으면 하나의 대표적인 최빈값을 정하기 어렵습니다.

```r
frequency <- table(fitness$sessions)
frequency
```

```
1 2 3 4 5
2 5 6 5 2
```

```
names(frequency)[frequency == max(frequency)]
```

```
[1] "3"
```

`table()`은 값별 도수를 계산합니다. 위 코드는 최대 도수에 해당하는 이름을 모두 반환합니다. **R의 `mode()`는 통계적 최빈값을 계산하는 함수가 아니라 객체의 저장 방식을 확인하는 함수**이므로 구분해야 합니다.

1.2.4 백분위수, 사분위수와 다섯 숫자 요약

백분위수(percentile)는 자료를 정렬했을 때의 상대적인 위치를 나타냅니다. **사분위수(quartile)**는 자료를 네 부분으로 나누는 위치값이며, 제1사분위수 Q_1은 25%, 제2사분위수 Q_2는 50%, 제3사분위수 Q_3는 75% 위치에 해당합니다. Q_2는 중앙값입니다.

```
quantile(fitness$grip_kg, probs = c(0.25, 0.5, 0.75))
```

```
 25%  50%  75%
31.0 34.5 38.5
```

```
quantile(fitness$grip_kg, probs = 0.9)
```

```
 90%
42.4
```

```
quantile(fitness$grip_kg, probs = c(0, 0.25, 0.5, 0.75, 1))
```

```
  0%  25%  50%  75% 100%
24.0 31.0 34.5 38.5 58.0
```

```
summary(fitness$grip_kg)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   24.0    31.0    34.5    35.7    38.5    58.0
```

최솟값, Q_1, 중앙값, Q_3, 최댓값을 **다섯 숫자 요약**이라고 합니다. `summary()`는 수치형 변수에 대해 이 값들과 평균을 함께 제공합니다. 표본 분위수는 계산 방법에 따라 조금 달라질 수 있으며, `quantile()`의 기본값은 `type = 7`입니다. 다른 프로그램의 결과와 비교할 때에는 계산 방식을 확인합니다.

1.3 산포와 상대적 변동

1.3.1 편차와 범위

산포(dispersion)는 관측값이 흩어져 있는 정도입니다. **편차(deviation)**는 각 관측값에서 평균을 뺀 값 $d_i = x_i - \bar{x}$입니다. 평균보다 크면 양수, 작으면 음수이며, 편차의 합은 이론적으로 0입니다. 따라서 편차를 그대로 평균하여 산포를 측정할 수는 없습니다.

```
x <- c(20, 25, 30, 35, 40)
deviation <- x - mean(x)
deviation
```

```
[1] -10  -5   0   5  10
```

```
sum(deviation)
```

```
[1] 0
```

```
range(x)
```

```
[1] 20 40
```

```
diff(range(x))
```

```
[1] 20
```

범위(range)는 최댓값과 최솟값의 차이입니다. R의 `range(x)`는 두 경계값을 반환하므로, 범위의 크기는 `diff(range(x))` 또는 `max(x) - min(x)`로 계산합니다. 위 예제의 범위는 20입니다. 범위는 두 극단값만 사용하므로 중간 관측의 분포는 반영하지 못합니다.

1.3.2 분산과 표준편차

분산(variance)은 편차를 제곱하여 요약한 값입니다. 유한 모집단 전체 N개의 값을 요약하는 모분산과, 표본으로 모집단의 분산을 추정할 때 사용하는 표본분산은 분모가 다릅니다.

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{N}(x_i - \mu)^2, \qquad s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2.$$

표준편차(standard deviation)는 분산의 양의 제곱근입니다. 분산의 단위는 원자료 단위의 제곱인 반면, 표준편차는 원자료와 같은 단위를 갖습니다. 예를 들어 악력의 단위가 kg이면 분산의 단위는 kg², 표준편차의 단위는 kg입니다.

표본평균을 사용하면 편차의 합이 0이라는 제약이 생겨 독립적으로 정할 수 있는 편차는 $n-1$개입니다. 이를 자유도 관점에서 설명할 수 있습니다. 또한 독립·동일분포 표본에서 $n-1$로 나눈 표본분산은 모집단 분산의 불편추정량이 됩니다.

```r
x <- c(20, 25, 30, 35, 40)
n <- length(x)
squared_deviation <- (x - mean(x))^2

sum(squared_deviation) / (n - 1)
```

```
[1] 62.5
```

```r
var(x)
```

```
[1] 62.5
```

```r
sd(x)
```

```
[1] 7.905694
```

```r
mean(squared_deviation)
```

```
[1] 50
```

```r
sqrt(mean(squared_deviation))
```

```
[1] 7.071068
```

`var(x)`와 `sd(x)`는 **분모가 $n-1$인 표본분산과 표본표준편차**를 계산합니다. 예제의 표본분산은 62.5, 표본표준편차는 약 7.91입니다. 다섯 관측값이 관심 모집단의 전체라면 분모 5를 사용하여 모분산 50, 모표준편차 약 7.07로 요약합니다. 데이터의 개수만으로 어느 공식을 쓸지 정하는 것이 아니라 분석 대상을 기준으로 구분합니다.

1.3.3 사분위범위

사분위범위(interquartile range, IQR)는 $Q_3 - Q_1$입니다. 가운데 약 50%의 자료가 분포하는 구간의 폭을 나타내며, 범위나 표준편차보다 극단값의 영향을 적게 받습니다.

```r
IQR(fitness$grip_kg)
```

```
[1] 7.5
```

```r
quantile(fitness$grip_kg, 0.75) - quantile(fitness$grip_kg, 0.25)
```

```
75%
7.5
```

분포가 대체로 대칭이고 극단값의 영향이 크지 않을 때에는 평균과 표준편차를, 비대칭이거나 극단값의 영향을 검토할 때에는 중앙값과 IQR을 함께 제시할 수 있습니다. 어느 한 조합만으로 분포 전체를 설명할 수 있는 것은 아닙니다.

1.3.4 변동계수

변동계수(coefficient of variation, CV)는 표준편차를 평균으로 나눈 값입니다. 여기서는 백분율로 나타냅니다.

$$\mathrm{CV} = \frac{s}{\bar{x}} \times 100\%.$$

표준편차가 절대적인 산포를 나타낸다면 변동계수는 **평균에 대한 상대적인 산포**를 나타냅니다. 예를 들어 악력 평균이 40kg이고 표준편차가 4kg인 집단의 CV는 10%, 평균이 20kg이고 표준편차가 4kg인 집단의 CV는 20%입니다. 표준편차가 같아도 평균에 대한 상대적 변동은 다릅니다.

```
cv_example <- data.frame(
  group = c("A", "B"),
  mean_kg = c(40, 20),
  sd_kg = c(4, 4)
)
cv_example$cv_percent <- cv_example$sd_kg / cv_example$mean_kg * 100
cv_example
```

```
  group mean_kg sd_kg cv_percent
1     A      40     4         10
2     B      20     4         20
```

```
sd(fitness$grip_kg) / mean(fitness$grip_kg) * 100
```

```
[1] 21.23763
```

변동계수는 **의미 있는 0을 갖는 비율척도**에서, 평균이 양수이며 0에서 충분히 떨어져 있을 때 해석하는 것이 적절합니다. 길이·질량·소요시간 등이 해당합니다. 섭씨온도처럼 0의 위치가 임의적인 척도, 평균이 0에 가깝거나 음수인 자료에는 그대로 적용하기 어렵습니다. 평균이 0에 가까워지면 작은 변화에도 CV가 크게 달라집니다.

단위가 달라도 상대적 변동을 표현할 수 있지만, 서로 다른 측정항목의 CV만으로 측정의 우수성이나 집단의 수행능력을 판단할 수는 없습니다. 예를 들어 CV가 작다는 것은 평균 대비 퍼짐이 작다는 뜻이며, 평균 수준이 높다는 뜻은 아닙니다.

1.3.5 결측값과 요약 통계표

`NA`는 값이 관측되지 않았거나 누락되었음을 나타냅니다. 많은 요약 함수는 자료에 `NA`가 포함되면 기본적으로 `NA`를 반환합니다. `na.rm = TRUE`를 사용하면 결측값을 제외하여 계산하지만, 누락의 원인과 제외된 관측 수도 함께 확인해야 합니다.

```
x_missing <- c(20, 25, NA, 35, 40)
mean(x_missing)
```

```
[1] NA
```

```
mean(x_missing, na.rm = TRUE)
```

```
[1] 30
```

```r
sum(is.na(x_missing))
```

```
[1] 1
```

```r
sum(!is.na(x_missing))
```

```
[1] 4
```

다음은 악력의 중심위치와 산포를 한 표에 정리한 예제입니다. 완전 관측된 실습 자료를 사용하며, 실제 자료에서는 변수별 유효 관측 수가 다를 수 있습니다.

```r
grip <- fitness$grip_kg
summary_grip <- data.frame(
  n = length(grip),
  mean = mean(grip),
  median = median(grip),
  variance = var(grip),
  sd = sd(grip),
  min = min(grip),
  max = max(grip),
  IQR = IQR(grip),
  CV_percent = sd(grip) / mean(grip) * 100
)
round(summary_grip, 2)
```

```
   n mean median variance   sd min max IQR CV_percent
1 20 35.7   34.5    57.48 7.58  24  58 7.5      21.24
```

1.4 변수 유형에 따른 기본 시각화

1.4.1 도수분포표와 상대도수

범주형 자료와 값의 종류가 많지 않은 이산형 자료는 **도수분포표**로 요약할 수 있습니다. 도수는 각 값이 관측된 횟수이며, 상대도수는 도수를 전체 관측 수로 나눈 값입니다.

```r
group_frequency <- table(fitness$group)
group_frequency
```

```

 A  B
10 10
```

```r
prop.table(group_frequency)
```

```
   A   B
0.5 0.5
```

```r
session_frequency <- table(factor(fitness$sessions, levels = 0:5))
data.frame(
  sessions = names(session_frequency),
  frequency = as.vector(session_frequency),
  percent = as.vector(prop.table(session_frequency)) * 100
)
```

```
  sessions frequency percent
1        0         0       0
2        1         2      10
3        2         5      25
4        3         6      30
5        4         5      25
6        5         2      10
```

`levels = 0:5`를 지정하면 관측되지 않은 0회도 도수 0으로 표시됩니다. 이 변환은 도수표를 만드는 데 사용한 것이며, 원자료 `fitness$sessions`는 수치형으로 유지됩니다. 이산형 자료라도 가능한 값이 매우 많으면 구간으로 묶어 분포를 요약할 수 있습니다.

1.4.2 막대그래프와 원그래프

막대그래프는 범주 또는 이산적인 값별 도수·비율을 비교하는 데 적합합니다. `barplot()`에는 원자료 대신 `table()` 등으로 집계한 값을 전달합니다.

```r
barplot(
  session_frequency,
  col = "steelblue",
  main = "주간 운동 횟수의 분포",
  xlab = "주간 운동 횟수 (회)",
  ylab = "도수 (명)",
  ylim = c(0, max(session_frequency) + 1)
)
```

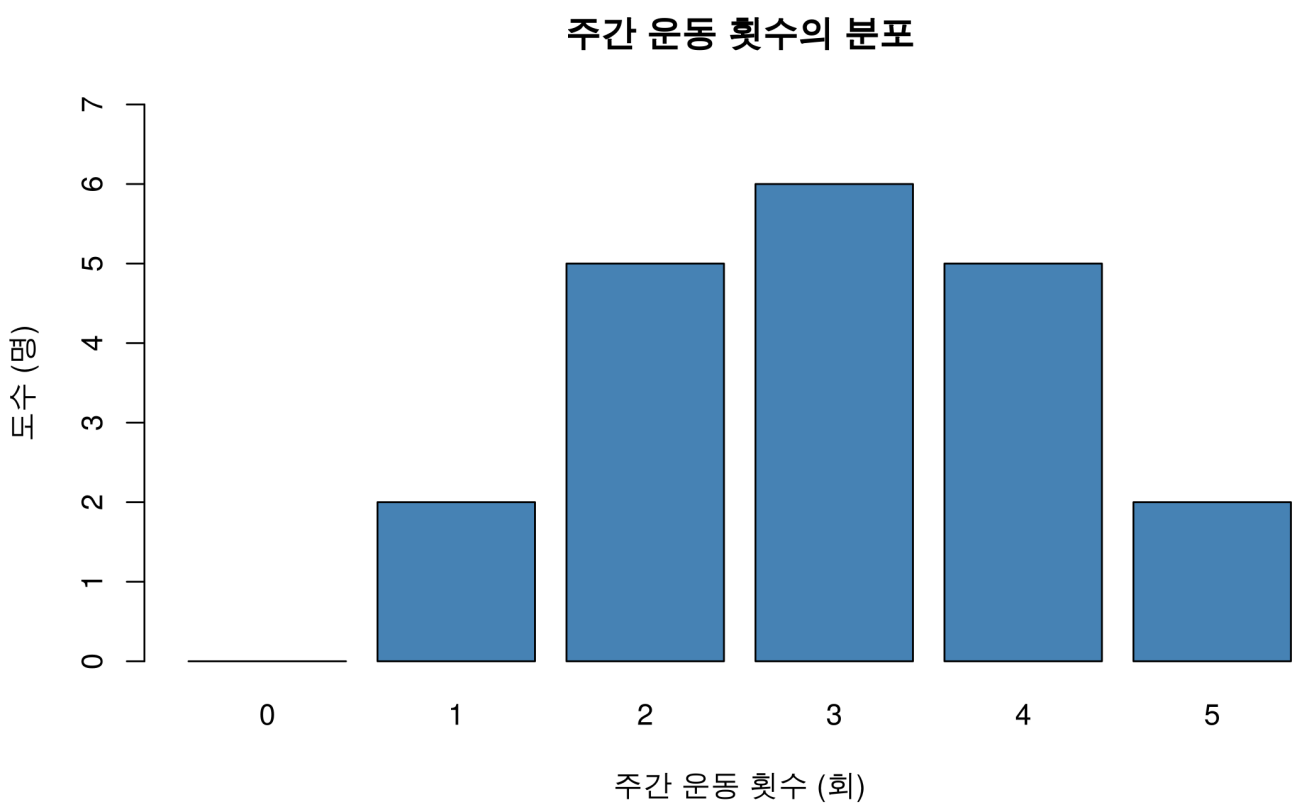


그림 1.1: 주간 운동 횟수별 관측 수. 도수가 0인 값도 표시합니다.

막대 사이에는 간격이 있으며, 각 막대는 하나의 범주 또는 값을 나타냅니다. 명목형 범주는 분석 목적에 따라 순서를 바꿀 수 있지만, 운동 횟수나 순서형 범주는 의미 있는 순서를 유지하는 것이 적절합니다.

원그래프는 전체에서 각 범주가 차지하는 비율을 보여 줍니다. 범주 수가 적고 부분과 전체의 관계를 나타낼 때 사용할 수 있습니다. 범주가 많거나 비율이 비슷한 경우에는 막대그래프가 비교에 더 적합합니다.

```
pie(
  group_frequency,
  labels = paste0(names(group_frequency), ": ",
                  prop.table(group_frequency) * 100, "%"),
  col = c("lightblue", "gray80"),
  main = "집단별 구성비"
)
```

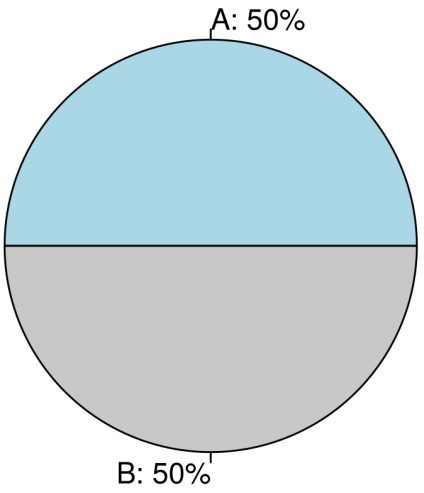


그림 1.2: 집단별 구성비. 가상 자료는 각 집단 10명으로 구성되어 있습니다.

1.4.3 히스토그램과 계급

히스토그램(histogram)은 수치형 자료를 구간으로 나누어 분포를 표현하는 그래프입니다. 각 구간을 **계급**, 구간의 너비를 **계급폭**이라고 합니다. 연속형 변수에서는 개별 값마다 막대를 만드는 것보다 구간별로 요약하는 것이 분포를 파악하는 데 유용합니다.

```
hist(
  fitness$grip_kg,
  breaks = seq(20, 60, by = 10),
  right = FALSE,
  col = "lightblue", border = "white",
  main = "악력의 분포",
  xlab = "악력 (kg)", ylab = "도수 (명)"
)
```

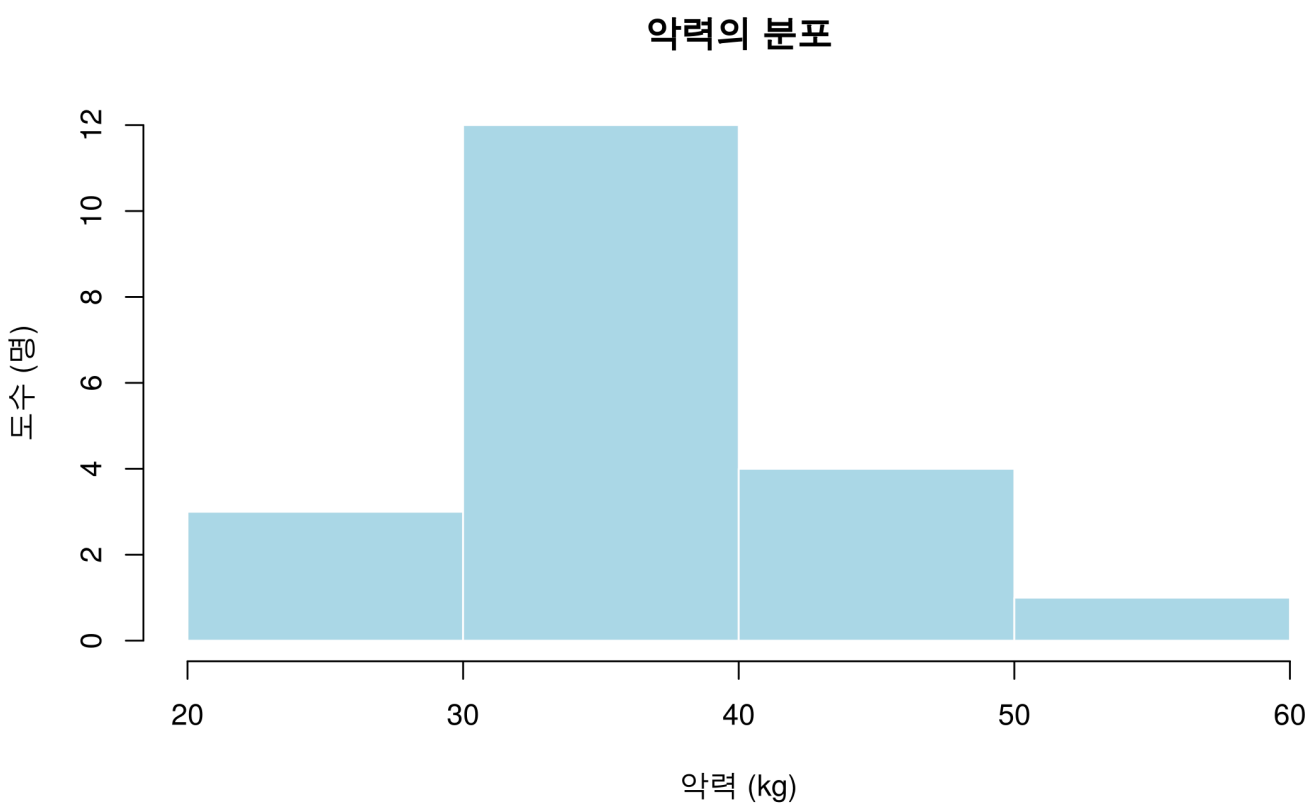


그림 1.3: 악력의 히스토그램. 계급폭을 10kg으로 지정한 결과입니다.

`seq(20, 60, by = 10)`은 계급 경계 20, 30, 40, 50, 60을 생성합니다. `right = FALSE`이면 원칙적으로 `[20, 30)`처럼 왼쪽 경계를 포함하고 오른쪽 경계를 제외합니다. 이 예제에서는 기본값 `include.lowest = TRUE`에 의해 마지막 구간의 오른쪽 끝 60도 포함됩니다.

막대그래프와 달리 히스토그램의 가로축은 수치의 구간을 나타내며 막대 사이에 간격을 두지 않습니다. **계급폭이 같을 때 도수 높이로 비교**할 수 있습니다. 계급폭이 다르면 높이 대신 면적이 비율에 대응하도록 밀도 척도를 사용해야 합니다. R의 `hist()`는 계급폭이 다른 경우 기본적으로 밀도를 표시합니다.

계급 수와 폭은 분포의 인상에 영향을 줍니다. 첨부 자료에서는 관측 수의 제곱근 등을 계급 수 결정의 참고값으로 제시합니다. 이는 고정 규칙이 아니므로 측정 단위와 자료의 특성을 고려하고, 여러 구간 설정에서 형태가 유지되는지 확인합니다.

```
local({
  old_par <- par(mfrow = c(1, 2), mar = c(4, 4, 3, 1))
  on.exit(par(old_par))
  hist(fitness$grip_kg, breaks = seq(20, 60, 5), right = FALSE,
       col = "lightblue", main = "계급폭 5kg",
       xlab = "악력 (kg)", ylab = "도수 (명)")
  hist(fitness$grip_kg, breaks = seq(20, 60, 10), right = FALSE,
       col = "lightblue", main = "계급폭 10kg",
       xlab = "악력 (kg)", ylab = "도수 (명)")
})
```

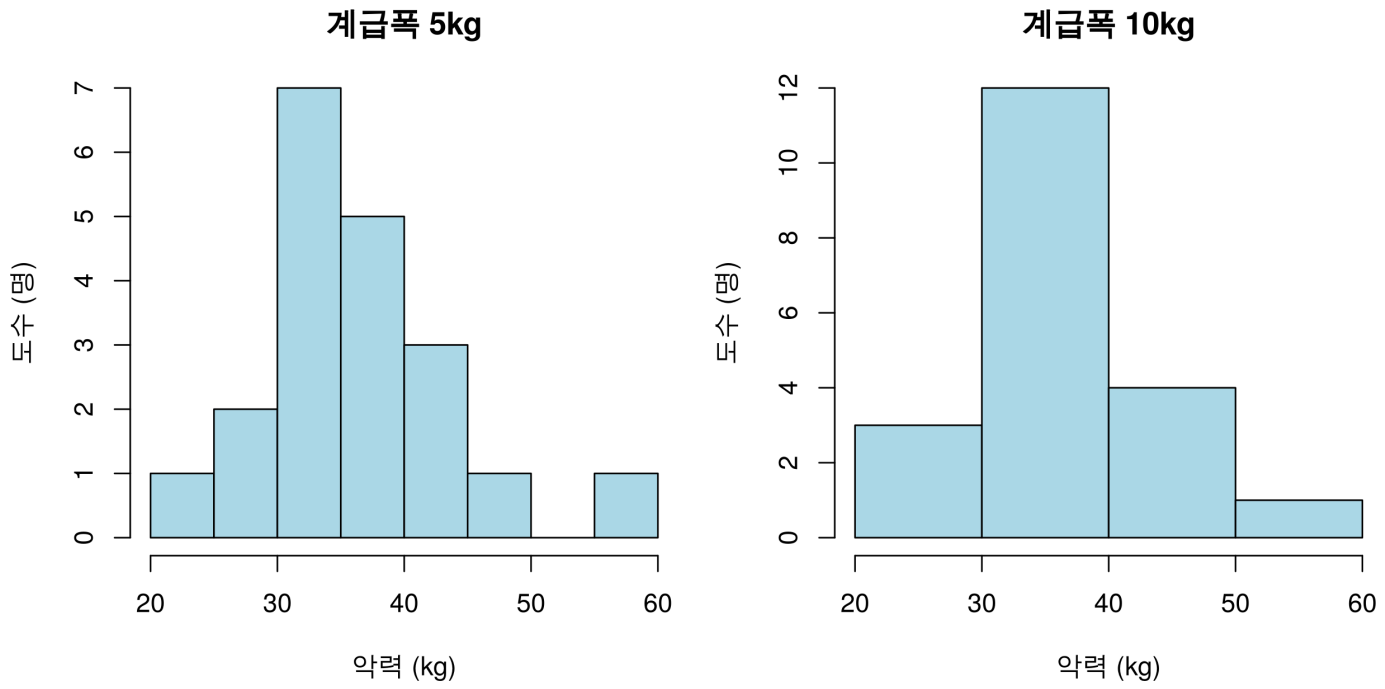


그림 1.4: 같은 자료에 계급폭 5kg과 10kg을 적용한 비교.

분포에서는 관측이 집중된 위치, 퍼짐, 대칭성, 꼬리 방향, 다른 값들과 떨어진 관측을 함께 살펴봅니다. 이 자료에는 상대적으로 큰 값 58kg이 있지만, 그래프에서 떨어져 보인다는 이유만으로 오류로 판단하지는 않습니다.

ⓘ 보충: 밀도곡선과 줄기-잎 그림

밀도곡선은 수치형 자료의 분포를 부드러운 곡선으로 추정한 결과입니다. 세로축은 도수가 아니라 확률밀도이며, 곡선 전체의 면적이 1이 되도록 구성됩니다. 곡선의 높이 자체를 특정 값의 확률로 해석하지 않습니다.

```
plot(
  density(fitness$grip_kg),
  main = "악력의 밀도곡선",
  xlab = "악력 (kg)", ylab = "밀도",
  col = "steelblue", lwd = 2
)
rug(fitness$grip_kg)
```

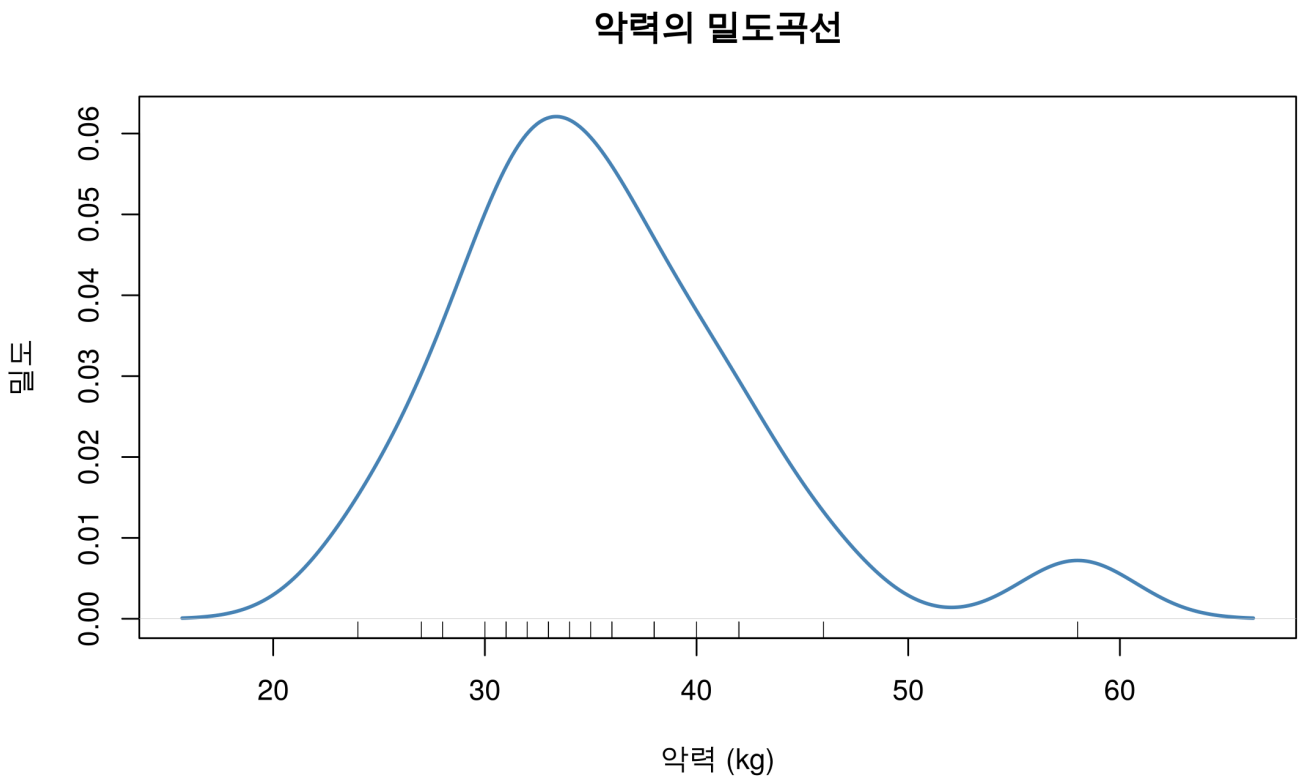


그림 1.5: 악력의 커널 밀도 추정. 표본이 작으므로 세부 형태의 해석에 유의합니다.

`rug()`는 가로축에 개별 관측의 위치를 표시합니다. 밀도곡선은 표본 크기와 평활 정도에 영향을 받으므로, 소규모 자료에서는 원자료와 함께 확인합니다.

줄기-잎 그림(stem-and-leaf plot)은 자릿수를 줄기와 잎으로 나누어 원자료의 값을 유지하면서 분포를 보여 줍니다. `stem()`은 Console에 결과를 출력합니다.

```
stem(fitness$grip_kg)
```

```
The decimal point is 1 digit(s) to the right of the |

2 | 478
3 | 011233456688
4 | 0226
5 | 8
```

출력 상단에 제시되는 소수점 위치를 기준으로 값을 읽습니다. 이 자료처럼 정수로 기록된 악력에서는 줄기와 잎을 결합하여 각 관측값을 확인할 수 있습니다.

1.4.4 상자그림과 집단별 분포

상자그림(boxplot)은 중앙값과 사분위수에 기초하여 분포를 요약합니다. 여러 집단의 중심과 퍼짐을 같은 축에서 비교하는 데 유용합니다.

```r
boxplot(
  grip_kg ~ group, data = fitness,
  col = c("lightblue", "gray80"),
  main = "집단별 악력 분포",
  xlab = "집단", ylab = "악력 (kg)"
)
```

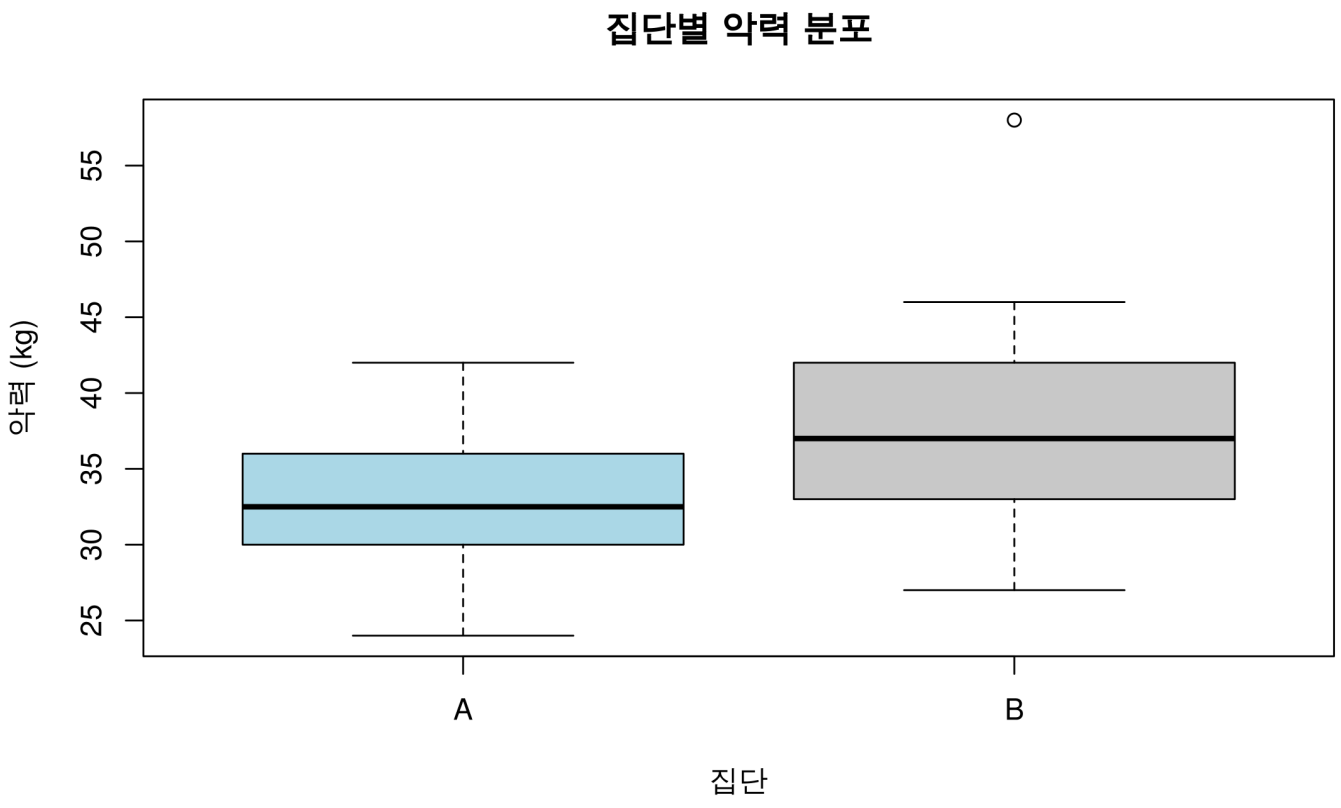


그림 1.6: 집단별 악력 분포. 표시는 분포 요약이며 집단 효과에 대한 검정 결과가 아닙니다.

`grip_kg ~ group`은 악력을 집단별로 구분하여 표시하는 수식입니다. 상자 안의 선은 중앙값, 상자의 아래와 위 경계는 하위·상위 사분위에 대응하는 경계입니다. R 기본 상자그림의 경계는 **힌지(hinge)**로 계산되므로, 표본 크기에 따라 `quantile()`의 기본 사분위수와 조금 다를 수 있습니다.

수염은 상자 경계에서 상자 높이의 1.5배 이내에 있는 관측 중 가장 먼 값까지 이어집니다. 그 밖의 관측은 개별 점으로 표시됩니다. 따라서 수염의 끝이 항상 최솟값과 최댓값을 나타내는 것은 아닙니다. 수염 밖의 점은 추가 검토 대상이며 자동으로 제거할 값은 아닙니다.

1.4.5 산점도와 선그래프

산점도는 두 수치형 변수의 관계를 나타냅니다. `plot(x, y)`에 두 측정값을 지정하면 각 관측이 하나의 점으로 표시됩니다.

```
plot(
  fitness$grip_kg, fitness$jump_cm,
  pch = 19, col = "steelblue",
  main = "악력과 점프 높이의 관계",
  xlab = "악력 (kg)", ylab = "점프 높이 (cm)"
)
```

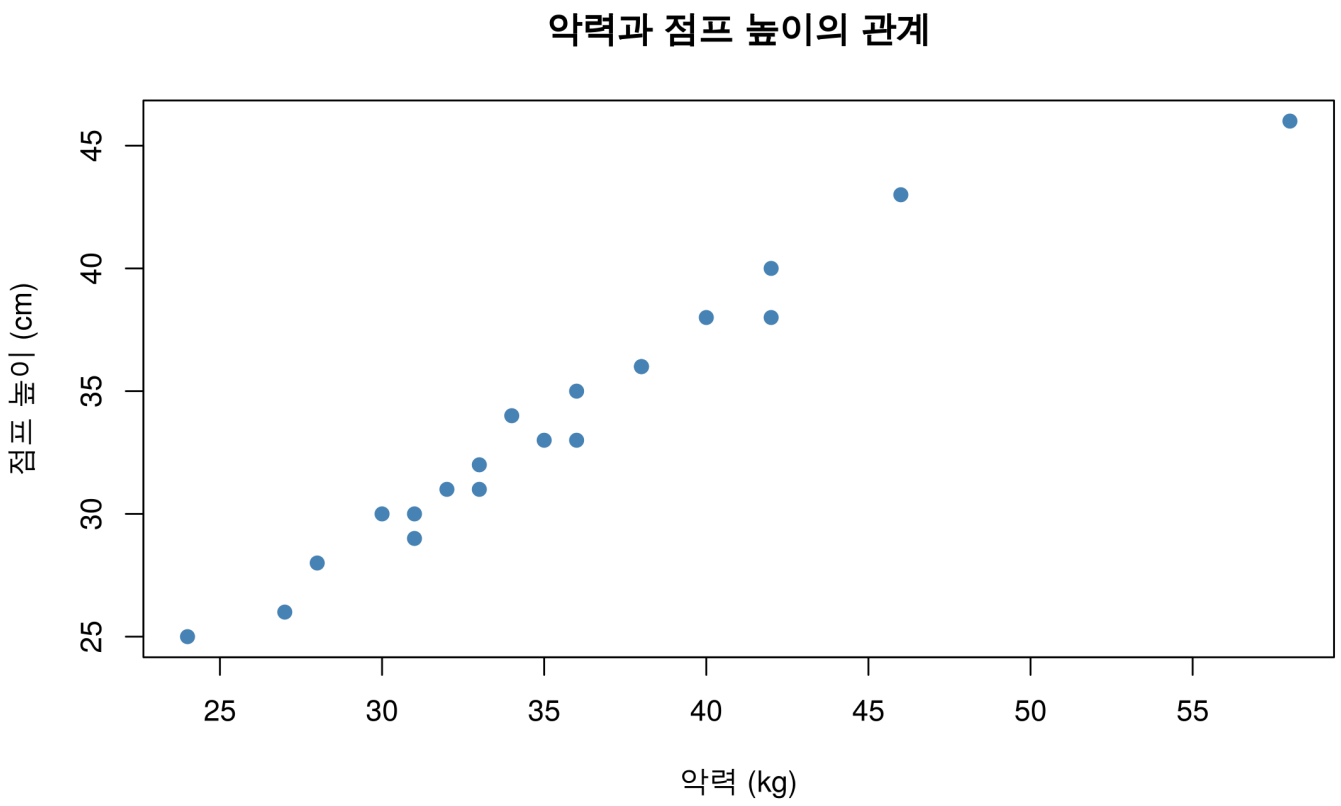


그림 1.7: 악력과 점프 높이의 산점도. 가상 자료에서 두 측정값의 관계를 살펴봅니다.

`pch`는 점의 모양, `col`은 색상을 지정합니다. 두 변수가 함께 증가하는 경향이 나타나지만, 이 그림만으로 악력이 점프 높이에 미치는 인과 효과를 판단할 수는 없습니다.

선그래프는 시간처럼 순서가 있는 축에서 값의 변화를 나타냅니다. 관측 순서를 정리한 뒤 `type = "b"`로 점과 선을 함께 표시할 수 있습니다.

```r
weekly <- data.frame(week = 1:6, grip_kg = c(30, 31, 30.5, 32, 33, 32.5))
plot(
  weekly$week, weekly$grip_kg,
  type = "b", pch = 19, col = "steelblue",
  main = "주차별 악력 변화",
  xlab = "주차", ylab = "악력 (kg)"
)
```

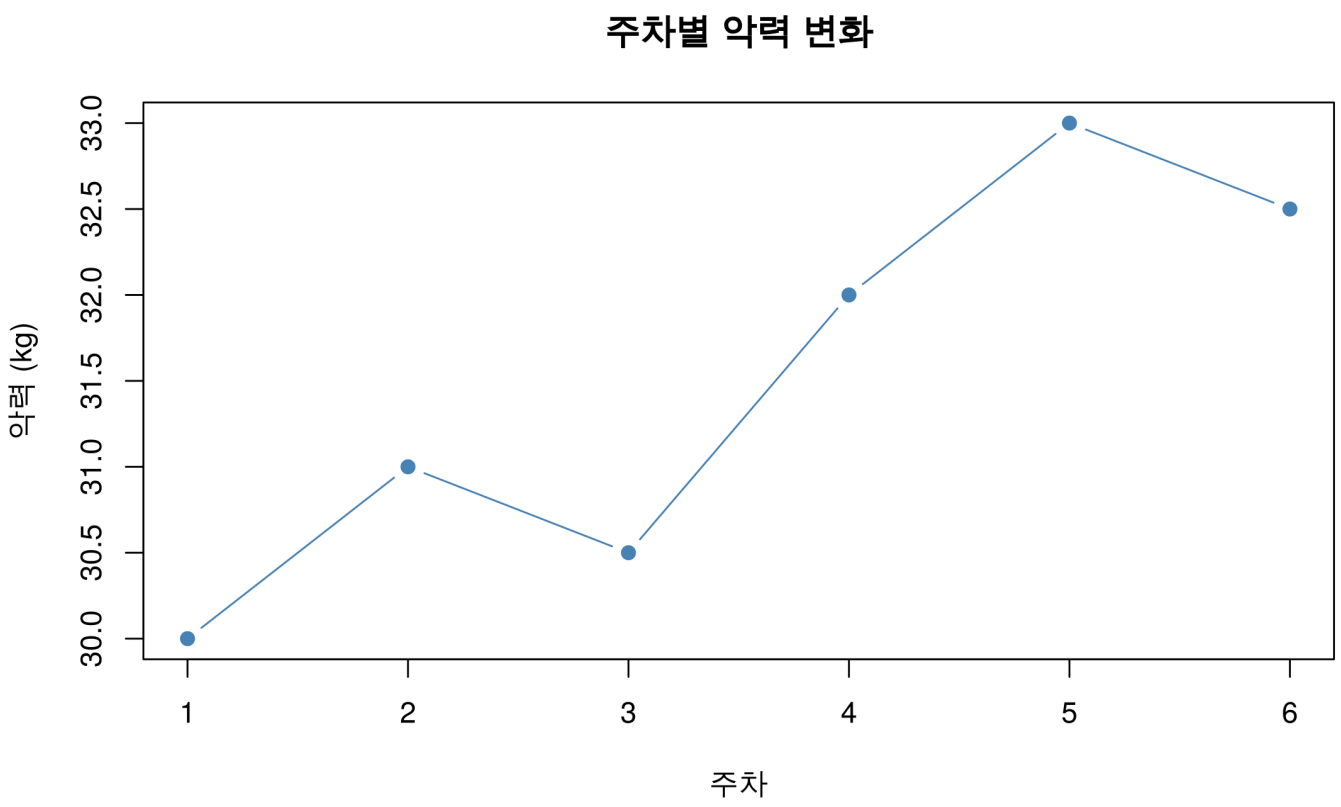


그림 1.8: 한 참여자의 주차별 악력 변화 예시. 별도로 구성한 가상 반복측정 자료입니다.

서로 다른 참여자의 행 순서나 명목형 범주의 나열에는 선으로 연결할 근거가 없을 수 있습니다. 선그래프는 연속형 변수에만 대응하는 그래프가 아니라, **시간과 같은 순서의 의미**를 전제로 선택하는 표현입니다.

1.5 집단별 요약과 그룹화 자료

1.5.1 집단별 요약 통계량

전체 평균만으로는 집단 간 특성을 파악하기 어렵습니다. `tapply()`를 사용하면 범주형 변수로 자료를 나누고 각 집단에 요약 함수를 적용할 수 있습니다.

```r
group_summary <- data.frame(
  group = levels(fitness$group),
  n = as.vector(table(fitness$group)),
  mean = as.vector(tapply(fitness$grip_kg, fitness$group, mean)),
  median = as.vector(tapply(fitness$grip_kg, fitness$group, median)),
  sd = as.vector(tapply(fitness$grip_kg, fitness$group, sd))
)
group_summary$CV_percent <- group_summary$sd / group_summary$mean * 100
group_summary
```

```
  group  n mean median       sd CV_percent
1     A 10 32.8   32.5 5.116422   15.59885
2     B 10 38.6   37.0 8.745793   22.65749
```

집단별 평균과 표준편차는 앞의 상자그림과 함께 해석합니다. 이 자료는 설명용이며, 두 집단의 평균 차이를 프로그램의 효과로 판단할 수는 없습니다.