제4장 국민체력 100 자료를 이용한 종합 실습

이 장에서는 `train_R`의 「국민체력 100 자료를 이용한 데이터 분석 예제」에 포함된 측정 자료를 이용하여 앞의 세 장을 종합적으로 실습합니다. 기술통계로 자료의 특성을 요약하고, 기본 R 그래프와 `ggplot2`로 분포와 관계를 확인한 뒤, 선형회귀모형으로 관계를 설명하고 예측합니다.

중심 분석 질문은 **"청소년의 상대악력이 높을수록 윗몸말아올리기 횟수도 많은가?"**입니다. 분석 대상과 변수의 단위를 먼저 정하고, 결측값 처리에 따라 표본 수가 어떻게 달라지는지 기록합니다. 각 절의 실습을 순서대로 실행한 뒤 마지막의 종합 과제를 수행합니다.

4.1 분석 질문과 자료 준비

4.1.1 앞 장과 실습의 연결

앞에서 다룬 내용	이 장의 실습	결과물
기술통계와 기본 R 시각화	도수·비율, 평균·분산·표준편차·변동계수, 분위수 계산	자료의 구성과 분포 요약표
ggplot2	막대그래프, 히스토그램, 상자그림, 산점도와 패널 작성	집단별 분포와 관계를 나타낸 그림
선형회귀분석	상관계수, `lm()`, 잔차 진단, `predict()`	회귀식, 적합도, 구간 예측과 해석

4.1.2 원자료와 실습 파일

원자료는 `train_R`에 포함된 `sample_data_sports100.xlsx`와 `column_info.xlsx`입니다. 실습에서는 측정 파일의 **전체 2,000행 중 필요한 11개 열**을 CSV로 옮긴 `sports100-practice.csv`를 사용합니다. 값과 결측값은 원본 그대로 유지했으며, 회원번호와 분석에 사용하지 않는 열은 포함하지 않았습니다. 변수 설명도 `sports100-variables.csv`로 제공합니다.

원고의 일부 설명에는 청소년 1,000명으로 기재되어 있으나, 실제 파일은 청소년·성인·어르신이 함께 있는 2,000건입니다. 이 장에서는 파일을 확인한 결과에 따라 분석 대상을 정합니다. 자료의 한 행을 **측정 기록 한 건**으로 해석하며, 표본의 모집단 대표성이 확인된 자료로 가정하지 않습니다.

강의 프로젝트를 사용하는 경우 자료는 `data` 폴더에 있습니다. 파일을 개별로 내려받으면 실습 CSV와 변수 설명 CSV를 Rmd 또는 R 코드가 있는 폴더의 `data` 하위 폴더에 저장합니다. 실행 파일이 있는 폴더를 작업 폴더로 지정합니다. 이 자료는 원본 강의에 포함된 표본 파일을 사용합니다.

```r
library(dplyr)
library(ggplot2)

nfa_raw <- read.csv("data/sports100-practice.csv", fileEncoding = "UTF-8-BOM")
nfa_info <- read.csv("data/sports100-variables.csv", fileEncoding = "UTF-8-BOM")

dim(nfa_raw)
```

```
[1] 2000   11
```

```r
str(nfa_raw)
```

```
'data.frame':   2000 obs. of  11 variables:
 $ AGE_GBN  : chr  "성인" "청소년" "성인" "청소년" ...
 $ TEST_AGE : int  59 17 19 13 17 15 46 33 38 17 ...
 $ TEST_MD  : chr  "2023-09-25" "2023-04-12" "2022-05-18" "2022-05-11" ...
 $ TEST_SEX : chr  "F" "F" "F" "F" ...
 $ ITEM_F001: num  160 160 163 157 169 ...
 $ ITEM_F002: num  51.5 75.8 57.4 61.4 67.1 59.4 81.1 78.3 74.7 53.7 ...
 $ ITEM_F007: num  23.4 31.2 21.8 28 24.9 39.4 47 40.1 42.9 36 ...
 $ ITEM_F008: num  23.8 34.2 23.8 30 29.9 39.4 48.2 48.2 49.1 39.1 ...
 $ ITEM_F009: int  NA NA NA NA 21 NA NA NA NA 23 ...
 $ ITEM_F010: int  NA 15 NA NA NA 43 NA NA NA NA ...
 $ ITEM_F018: num  20.2 29.7 21.6 24.8 23.5 21.7 25.9 25.6 25.9 17.5 ...
```

```r
head(nfa_raw)
```

```
  AGE_GBN TEST_AGE    TEST_MD TEST_SEX ITEM_F001 ITEM_F002 ITEM_F007 ITEM_F008
1    성인       59 2023-09-25        F     159.6      51.5      23.4      23.8
2  청소년       17 2023-04-12        F     159.8      75.8      31.2      34.2
3    성인       19 2022-05-18        F     162.9      57.4      21.8      23.8
4  청소년       13 2022-05-11        F     157.4      61.4      28.0      30.0
5  청소년       17 2024-06-20        F     168.9      67.1      24.9      29.9
6  청소년       15 2022-09-19        M     165.4      59.4      39.4      39.4
  ITEM_F009 ITEM_F010 ITEM_F018
1        NA        NA      20.2
2        NA        15      29.7
3        NA        NA      21.6
4        NA        NA      24.8
5        21        NA      23.5
6        NA        43      21.7
```

4.1.3 변수의 의미와 단위

원래 변수명	내용	분석할 때의 유형과 단위
`AGE_GBN`	연령 구분	범주형: 청소년·성인·어르신
`TEST_AGE`	연령	수치형, 세
`TEST_MD`	측정일	날짜
`TEST_SEX`	성별 코드	범주형: M·F
`ITEM_F001`	신장	연속형 측정값, cm
`ITEM_F002`	체중	연속형 측정값, kg
`ITEM_F007`, `ITEM_F008`	왼손·오른손 악력	연속형 측정값, kg
`ITEM_F009`	윗몸말아올리기	이산형 수치, 회
`ITEM_F010`	반복점프	이산형 수치, 회
`ITEM_F018`	BMI	연속형 수치, kg/m²

윗몸말아올리기 횟수는 이산형이지만, 횟수의 평균이나 회귀분석을 할 때에는 숫자로 사용합니다. 성별과 연도별 집단을 구분할 때에는 `factor`를 사용합니다.

실습 1. 연령 구분별 기록 수와 성별 기록 수를 확인합니다. 전체 자료를 청소년 자료로 해석할 수 있는지 판단합니다.

```
table(nfa_raw$AGE_GBN, useNA = "ifany")
```

```
  성인 어르신 청소년
  1128     25    847
```

```
table(nfa_raw$TEST_SEX, useNA = "ifany")
```

```
   F    M
 754 1246
```

```
range(nfa_raw$TEST_AGE, na.rm = TRUE)
```

```
[1] 13 65
```

전체 기록은 청소년 847건, 성인 1,128건, 어르신 25건으로 구성되어 있습니다. 이후 분석은 **청소년으로 구분되어 있으면서 연령이 13–18세인 기록**으로 한정합니다.

4.2 분석 자료 구성과 결측값 점검

4.2.1 변수 이름과 자료형 정리

`select()`로 필요한 열을 고르면서 읽기 쉬운 이름을 부여합니다. `mutate()`는 열의 변환 또는 생성을, `filter()`는 조건에 맞는 행의 선택을 수행합니다. `%>%`는 앞 단계의 결과를 다음 함수로 전달합니다.

```
nfa <- nfa_raw %>%
  select(
    age_group = AGE_GBN, age = TEST_AGE, test_date = TEST_MD,
    sex = TEST_SEX, height_cm = ITEM_F001, weight_kg = ITEM_F002,
    grip_left = ITEM_F007, grip_right = ITEM_F008,
    curl_up = ITEM_F009, jump_count = ITEM_F010, bmi = ITEM_F018
  ) %>%
  mutate(
    test_date = as.Date(test_date),
    year = factor(format(test_date, "%Y")),
    sex = factor(sex, levels = c("M", "F"), labels = c("남성", "여성")),
    age_group = factor(age_group, levels = c("청소년", "성인", "어르신"))
  )

teen_raw <- nfa %>%
  filter(age_group == "청소년", age >= 13, age <= 18)

nrow(teen_raw)
```

```
[1] 847
```

```
table(teen_raw$year, teen_raw$sex)
```

```
      남성 여성
  2020   26   17
  2021  113   65
  2022  129   96
  2023  118   74
  2024  127   82
```

날짜에서 연도를 추출한 뒤 factor로 저장했습니다. 연도를 숫자 연산에 이용하려는 것이 아니라 집단별로 비교하기 위해서입니다. 연령은 숫자로 유지합니다. `as.Date()`는 이 파일의 `YYYY-MM-DD` 형식에 맞는 변환입니다.

4.2.2 결측값과 선택 측정 항목

실습 2. 각 측정 항목의 결측값 수를 구하고, 윗몸말아올리기와 반복점프의 측정 여부를 교차표로 확인합니다.

```r
colSums(is.na(teen_raw[c("height_cm", "weight_kg", "grip_left",
                         "grip_right", "curl_up", "jump_count", "bmi")]))
```

```
  height_cm  weight_kg  grip_left grip_right    curl_up jump_count        bmi
          0          0          2          2        512        353          0
```

```r
with(teen_raw, table(
  윗몸말아올리기_측정 = !is.na(curl_up),
  반복점프_측정 = !is.na(jump_count)
))
```

```
                    반복점프_측정
 윗몸말아올리기_측정 FALSE TRUE
               FALSE    19  493
               TRUE    334    1
```

원본 예제는 두 근지구력 항목을 선택 측정 항목으로 설명합니다. 실제 청소년 자료에는 윗몸말아올리기만 있는 기록 334건, 반복점프만 있는 기록 493건, 둘 다 있는 기록 1건, 둘 다 없는 기록 19건이 있습니다. 따라서 모든 열에 `na.omit()`을 적용하면 분석에 필요하지 않은 항목의 결측값 때문에도 기록이 제외됩니다.

윗몸말아올리기를 측정하지 않은 경우의 `NA`와 실제 수행 횟수 **0회**를 구분해야 합니다. 결측값을 0으로 바꾸면 평균과 회귀계수가 달라집니다. 이후에는 **각 분석에 필요한 변수에 대해서만** 사용 가능한 기록을 선택합니다.

4.2.3 변수 설명서의 범위 확인

`column_info.xlsx`의 `min_teen`, `max_teen`에는 청소년 측정값의 점검 범위가 제시되어 있습니다. 이 범위는 제공된 강의 자료의 점검 기준이며, 임상적 정상 범위나 공식 체력 인증 기준으로 해석하지 않습니다.

```r
nfa_info %>%
  filter(varname_eng %in% c("ITEM_F002", "ITEM_F007", "ITEM_F008", "ITEM_F009")) %>%
  select(varname_eng, varname_kor, unit, min_teen, max_teen)
```

```
   varname_eng    varname_kor unit min_teen max_teen
1   ITEM_F002           체중   kg       20      140
2   ITEM_F007        악력_좌   kg        1      100
3   ITEM_F008        악력_우   kg        1      100
4   ITEM_F009 윗몸말아올리기   회        0      100
```

```r
teen_raw %>%
  summarise(
    weight_outside = sum(weight_kg < 20 | weight_kg > 140, na.rm = TRUE),
    left_outside = sum(grip_left < 1 | grip_left > 100, na.rm = TRUE),
    right_outside = sum(grip_right < 1 | grip_right > 100, na.rm = TRUE),
    curl_outside = sum(curl_up < 0 | curl_up > 100, na.rm = TRUE)
  )
```

```
   weight_outside left_outside right_outside curl_outside
1              0            0             0            3
```

```
table(teen_raw$curl_up[!is.na(teen_raw$curl_up) & teen_raw$curl_up > 100])
```

```

 120
   3
```

윗몸말아올리기 120회인 기록 3건이 설명서의 상한 100회를 초과합니다. 이 사실만으로 입력 오류라고 단정할 수는 없습니다. 본 실습의 주 분석에서는 해당 값들을 제외 대상으로 표시하고, 원본 값을 보존한 별도 열에서 결측값으로 처리합니다. 마지막 과제에서는 이 세 건을 포함했을 때 결과가 달라지는지 비교합니다.

```
teen <- teen_raw %>%
  mutate(
    curl_flag = !is.na(curl_up) & (curl_up < 0 | curl_up > 100),
    curl_clean = ifelse(curl_flag, NA_real_, curl_up)
  )
```

체중과 좌우 악력은 위의 점검에서 범위 밖 값이 없으므로 그대로 사용합니다. 다른 자료를 분석할 때에는 해당 점검 결과에 따라 처리 여부를 판단해야 합니다.

4.2.4 상대악력 계산과 분석 표본 확정

원본 예제와 동일하게 좌우 악력 중 큰 값을 체중으로 나누어 **상대악력**을 계산합니다.

$$\text{상대악력}(\%) = \frac{\max(\text{왼손 악력}, \text{오른손 악력})}{\text{체중}} \times 100$$

```
teen <- teen %>%
  mutate(
    grip_max = pmax(grip_left, grip_right, na.rm = TRUE),
    grip_max = ifelse(is.na(grip_left) & is.na(grip_right), NA_real_, grip_max),
    grip_rel = ifelse(weight_kg > 0, grip_max / weight_kg * 100, NA_real_)
  )

reg_data <- teen %>%
  filter(!is.na(sex), is.finite(grip_rel), is.finite(curl_clean))

sample_flow <- data.frame(
  단계 = c("원본 측정 기록", "13-18세 청소년", "상대악력 계산 가능",
           "윗몸말아올리기 측정", "범위 점검 후 윗몸말아올리기",
           "두 변수와 성별이 있는 회귀분석 자료"),
  기록수 = c(nrow(nfa_raw), nrow(teen), sum(is.finite(teen$grip_rel)),
             sum(!is.na(teen$curl_up)), sum(!is.na(teen$curl_clean)), nrow(reg_data))
)
sample_flow
```

```
                                  단계 기록수
1                          원본 측정 기록    2000
2                          13-18세 청소년     847
3                       상대악력 계산 가능     845
4                      윗몸말아올리기 측정     335
5            범위 점검 후 윗몸말아올리기     332
6 두 변수와 성별이 있는 회귀분석 자료     332
```

```
table(reg_data$sex)
```

```
남성 여성
 206  126
```

`pmax()`는 같은 행의 두 값 중 큰 값을 반환합니다. 한 손만 측정된 경우에는 그 값을 사용하고, 두 손 모두 결측이면 상대악력도 결측으로 둡니다. 체중이 0 이하이면 나눗셈에 사용하지 않습니다. 이 자료에서 최종 회귀분석 대상은 **332건**이며 남성 206건, 여성 126건입니다. 표의 중간 단계는 각 항목의 사용 가능 수를 나타내므로 단순한 순차 삭제 수로 해석하지 않습니다.

4.3 기술통계와 기본 R 시각화

4.3.1 범주형 자료의 도수와 비율

실습 3. 청소년 전체 자료에서 성별 도수와 비율을 계산합니다. 다음으로 연도별 성별 비율을 계산하고, 비율의 분모가 어떻게 다른지 설명합니다.

```
sex_count <- table(teen$sex)
sex_count
```

```
남성 여성
 513  334
```

```
prop.table(sex_count) * 100
```

```
    남성     여성
60.56671 39.43329
```

```
year_sex <- table(teen$year, teen$sex)
year_sex
```

```
      남성 여성
2020   26   17
2021  113   65
2022  129   96
2023  118   74
2024  127   82
```

```r
round(prop.table(year_sex, margin = 1) * 100, 1)
```

```
      남성 여성
2020 60.5 39.5
2021 63.5 36.5
2022 57.3 42.7
2023 61.5 38.5
2024 60.8 39.2
```

`prop.table(sex_count)`는 청소년 전체 기록 수를 분모로 사용합니다. 교차표에서 `margin = 1`을 지정하면 각 행, 즉 **해당 연도 안의 기록 수**가 분모입니다. 이때 행별 비율의 합은 100%입니다. "전체에서의 비율"과 "연도 안에서의 비율"을 구분하여 보고합니다.

4.3.2 평균, 분산, 표준편차와 변동계수

실습 4. 상대악력의 평균, 중앙값, 분산, 표준편차, 사분위수와 변동계수를 계산합니다.

```r
grip_values <- teen$grip_rel[is.finite(teen$grip_rel)]

c(
  n = length(grip_values),
  mean = mean(grip_values),
  median = median(grip_values),
  variance = var(grip_values),
  sd = sd(grip_values),
  IQR = IQR(grip_values),
  CV_percent = sd(grip_values) / mean(grip_values) * 100
)
```

```
         n       mean     median   variance         sd        IQR CV_percent
 845.00000   52.94474   51.86207  169.03545   13.00136   18.96039   24.55648
```

```r
quantile(grip_values, probs = c(0, 0.25, 0.5, 0.75, 1))
```

```
      0%      25%      50%      75%     100%
21.65680 43.12977 51.86207 62.09016 96.88042
```

평균 상대악력은 약 52.94%, 표준편차는 약 13 **퍼센트포인트**입니다. 상대악력 40%와 50%의 차이는 10퍼센트포인트입니다. 이처럼 %로 표시한 값의 차이를 말할 때와 평균 대비 상대적 산포인 변동계수(%)를 말할 때는 의미를 구분합니다.

상대악력은 의미 있는 0을 갖는 양수 지표이므로 이 실습에서 변동계수를 계산할 수 있습니다. 변동계수로 다른 측정항목을 비교할 때에도 척도와 평균이 0에 가까운지 확인해야 합니다.

성별로 같은 요약을 반복하면 전체 평균에 가려진 집단 차이를 확인할 수 있습니다. 각 변수의 결측값 수가 다르므로 요약표에는 변수별 유효 관측 수를 표시합니다.

```
grip_summary <- teen %>%
  group_by(sex) %>%
  summarise(
    n_grip = sum(!is.na(grip_rel)),
    mean_grip = mean(grip_rel, na.rm = TRUE),
    sd_grip = sd(grip_rel, na.rm = TRUE),
    median_grip = median(grip_rel, na.rm = TRUE),
    cv_grip = sd_grip / mean_grip * 100,
    n_curl = sum(!is.na(curl_clean)),
    mean_curl = mean(curl_clean, na.rm = TRUE),
    .groups = "drop"
  )
grip_summary
```

```
# A tibble: 2 × 8
  sex    n_grip mean_grip sd_grip median_grip cv_grip n_curl mean_curl
  <fct>  <int>     <dbl>   <dbl>       <dbl>   <dbl>  <int>     <dbl>
1 남성     512      58.2   12.4         58.4    21.4    206      43.3
2 여성     333      44.9    9.15        43.9    20.4    126      24.1
```

`.groups = "drop"`은 요약이 끝난 뒤 그룹화 정보를 해제합니다. 위 표의 상대악력 평균과 윗몸말아올리기 평균은 각각 사용 가능한 기록으로 계산했으므로, 두 평균의 분석 대상이 완전히 같다고 가정하지 않습니다.

4.3.3 기본 R 그래프로 확인하기

실습 5. 성별 도수는 막대그래프, 상대악력 분포는 히스토그램으로 표현합니다. 그래프에서 읽을 수 있는 특징을 각각 한 문장으로 작성합니다.

```
barplot(sex_count, col = c("steelblue", "tan3"),
        xlab = "성별", ylab = "측정 기록 수 (건)")
```

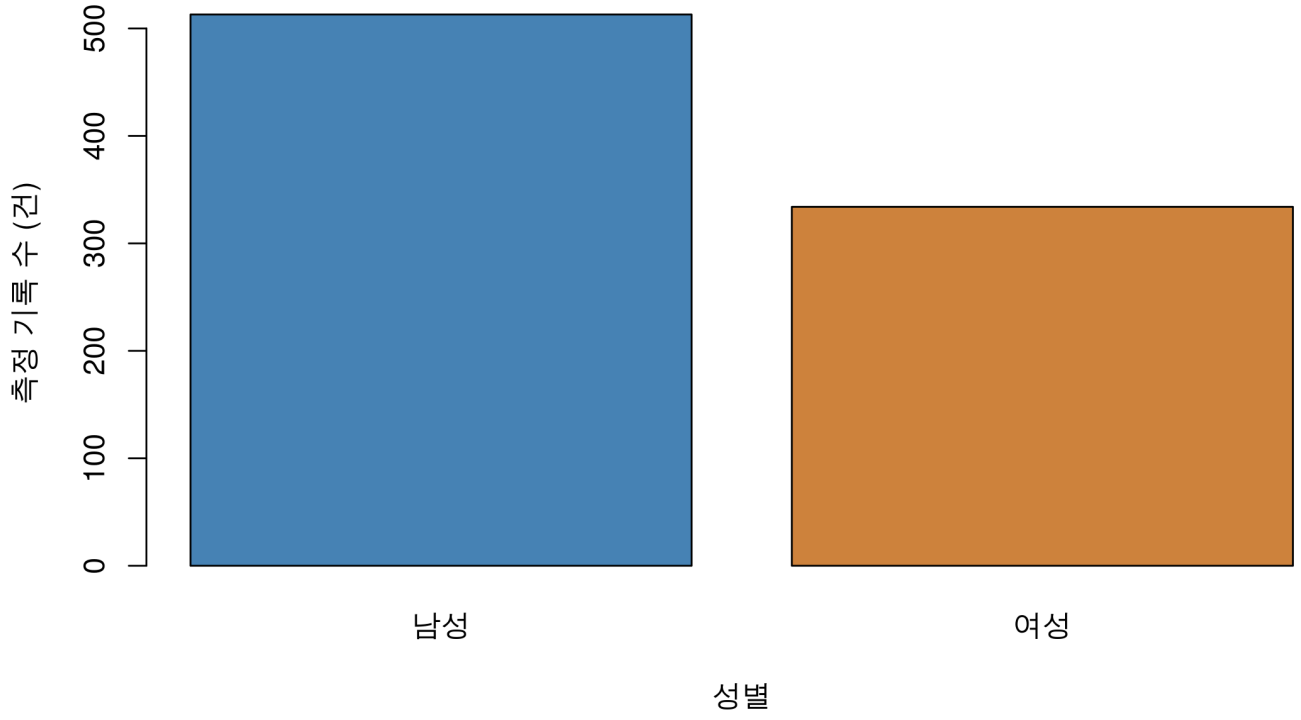


그림 4.1: 청소년 자료의 성별 측정 기록 수.

```
hist(grip_values, breaks = 15, col = "lightblue", border = "white",
     main = "", xlab = "상대악력 (%)", ylab = "도수 (건)")
```

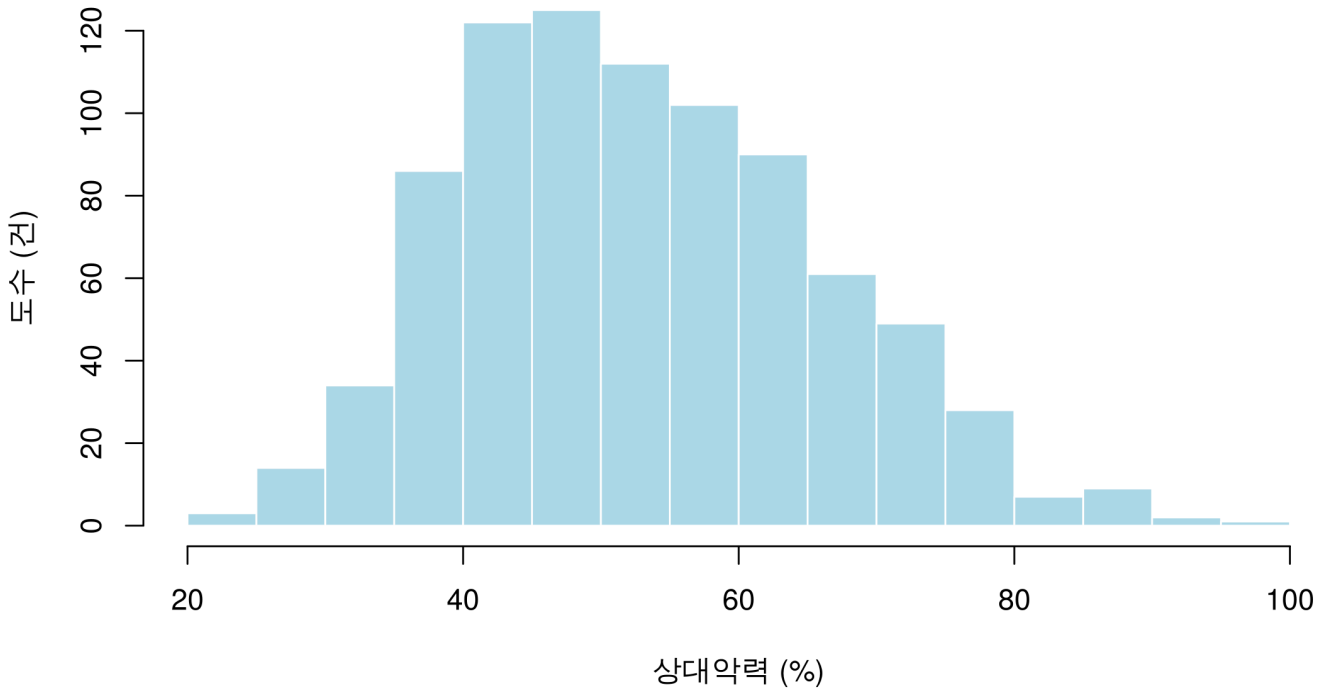


그림 4.2: 청소년 상대악력의 분포. 결측값을 제외한 자료입니다.

막대그래프의 성별은 서로 구분되는 범주이고, 히스토그램의 가로축은 연속적인 측정값의 구간입니다. 히스토그램은 `breaks`를 바꾸면 모양이 달라질 수 있으므로 한 가지 구간 설정만으로 분포를 판단하지 않습니다.

4.4 ggplot2로 분포와 관계 탐색

4.4.1 도수와 요약값의 시각화

실습 6. 연도별 성별 기록 수를 막대그래프로 나타내고, 성별 평균 상대악력을 별도의 그래프로 나타냅니다. 두 그래프에서 `geom_bar()`와 `geom_col()`을 다르게 사용하는 이유를 설명합니다.

```
ggplot(teen, aes(x = year, fill = sex)) +
  geom_bar(position = "dodge") +
  labs(x = "측정 연도", y = "측정 기록 수 (건)", fill = "성별")
```

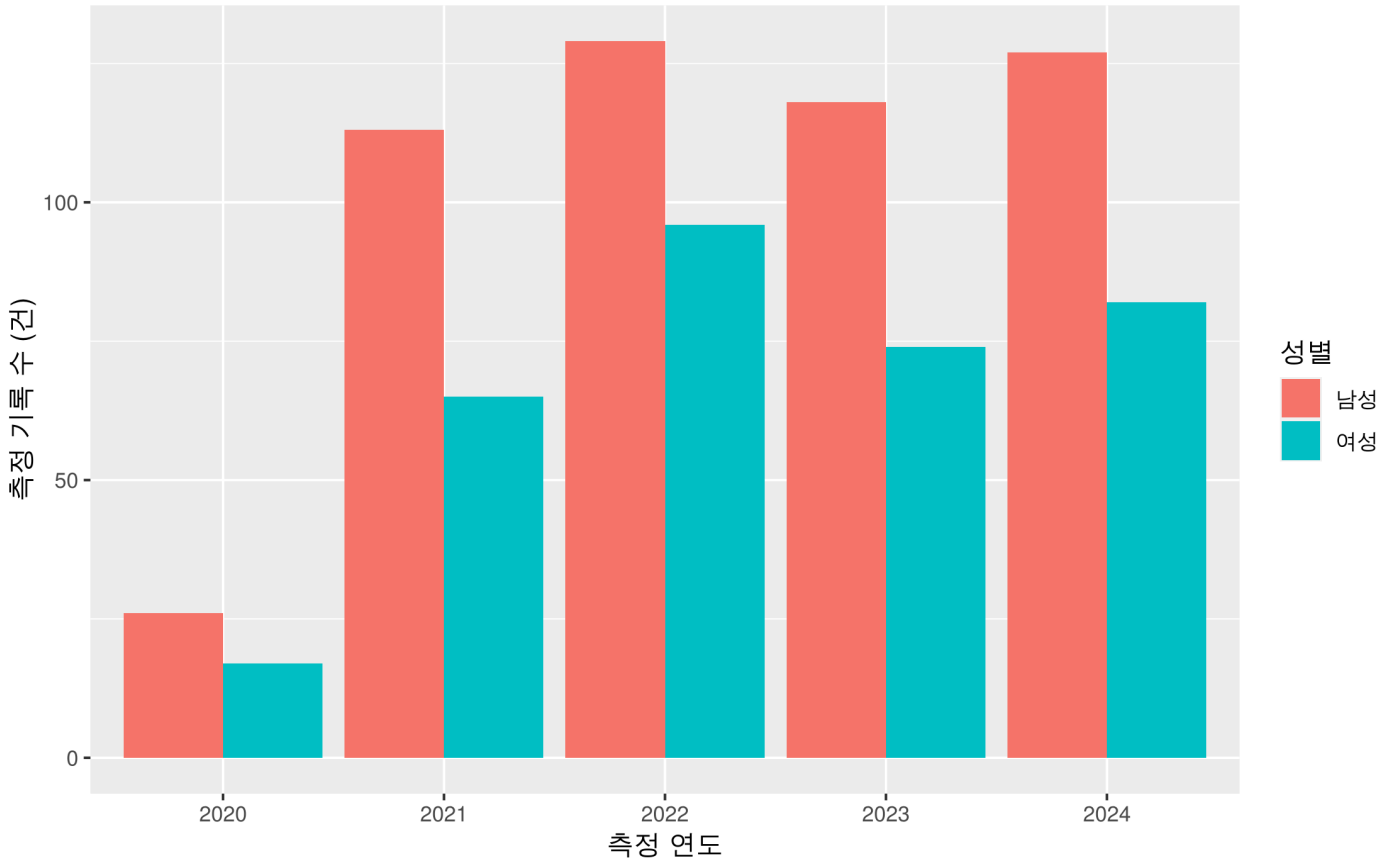


그림 4.3: 연도별 성별 기록 수. 각 막대는 측정 기록의 도수입니다.

```
p_grip_mean <- ggplot(grip_summary, aes(x = sex, y = mean_grip, fill = sex)) +
  geom_col(width = 0.6, show.legend = FALSE) +
  labs(x = "성별", y = "평균 상대악력 (%)")
p_grip_mean
```

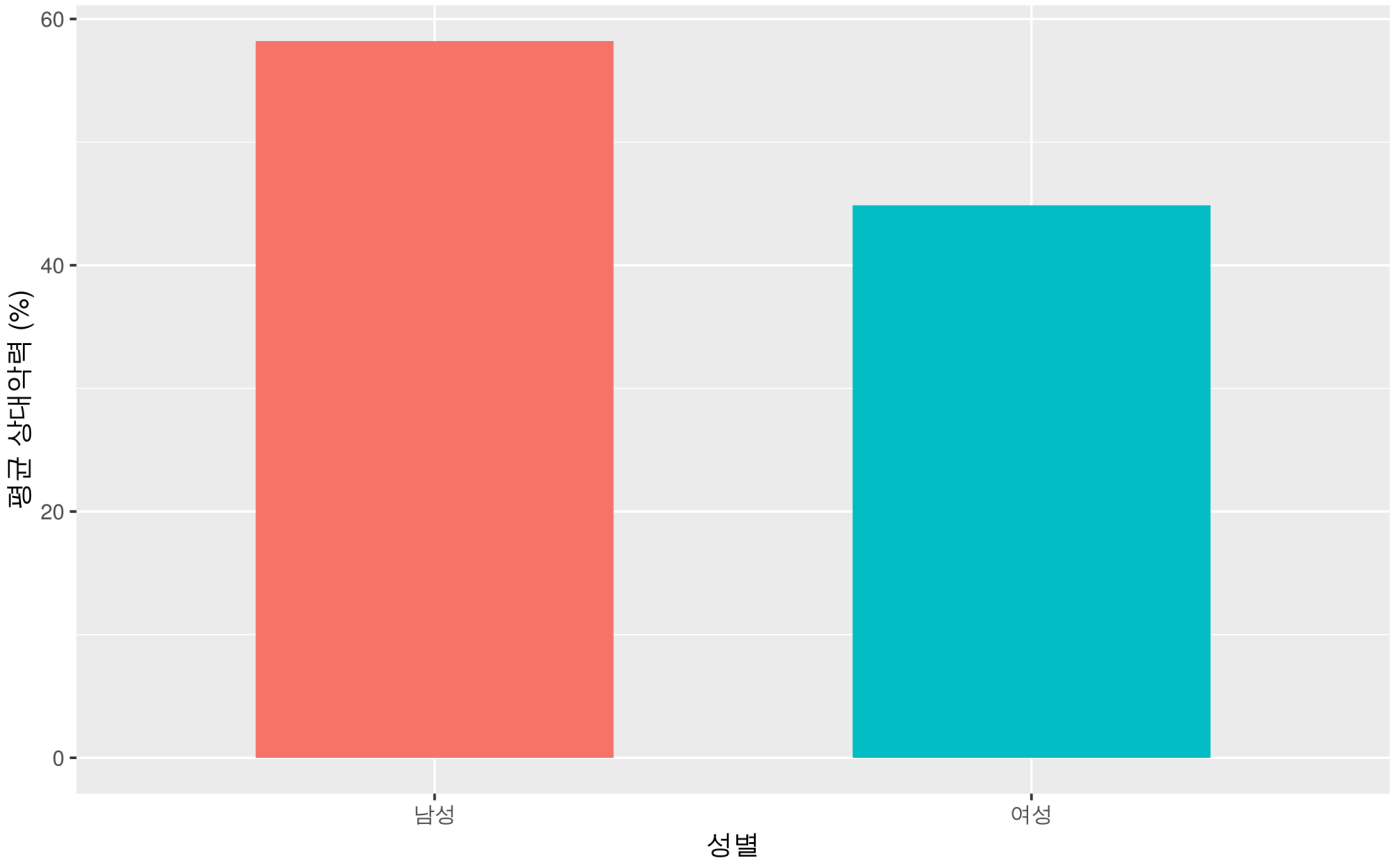


그림 4.4: 성별 평균 상대악력. 막대의 높이는 이미 계산한 평균입니다.

`geom_bar()`는 입력 자료의 행을 세어 도수를 계산합니다. `geom_col()`은 `grip_summary`에 이미 계산된 `mean_grip`을 막대의 높이로 사용합니다. 평균만으로는 집단 안의 산포를 알 수 없으므로 표준편차와 분포 그림도 함께 확인합니다.

4.4.2 집단별 분포 비교

실습 7. 상대악력의 분포를 성별 패널로 나누고, 청소년의 연도별 BMI 분포를 성별 상자그림으로 비교합니다.

```
ggplot(filter(teen, !is.na(grip_rel)), aes(x = grip_rel)) +
  geom_histogram(binwidth = 5, boundary = 0, fill = "steelblue", color = "white") +
  facet_wrap(~ sex) +
  labs(x = "상대악력 (%)", y = "도수 (건)")
```

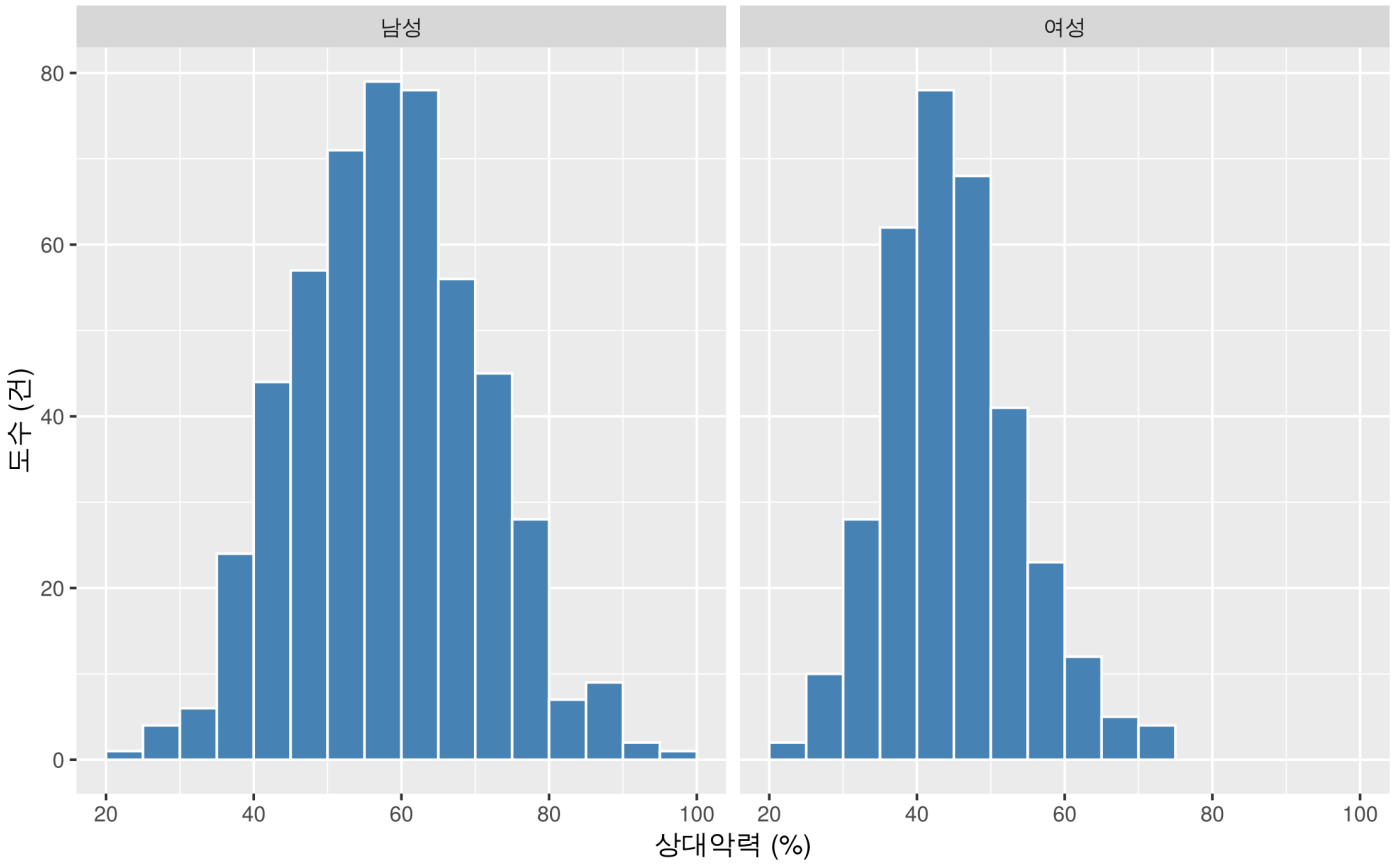


그림 4.5: 같은 구간 너비로 작성한 성별 상대악력 히스토그램.

두 패널은 같은 축과 구간 너비를 사용합니다. 성별 표본 수가 다르므로 막대 높이의 차이에 표본 수의 차이도 반영됩니다.

```
ggplot(teen, aes(x = year, y = bmi, fill = sex)) +
  geom_boxplot(outlier.alpha = 0.4) +
  labs(x = "측정 연도", y = "BMI (kg/m²)", fill = "성별")
```

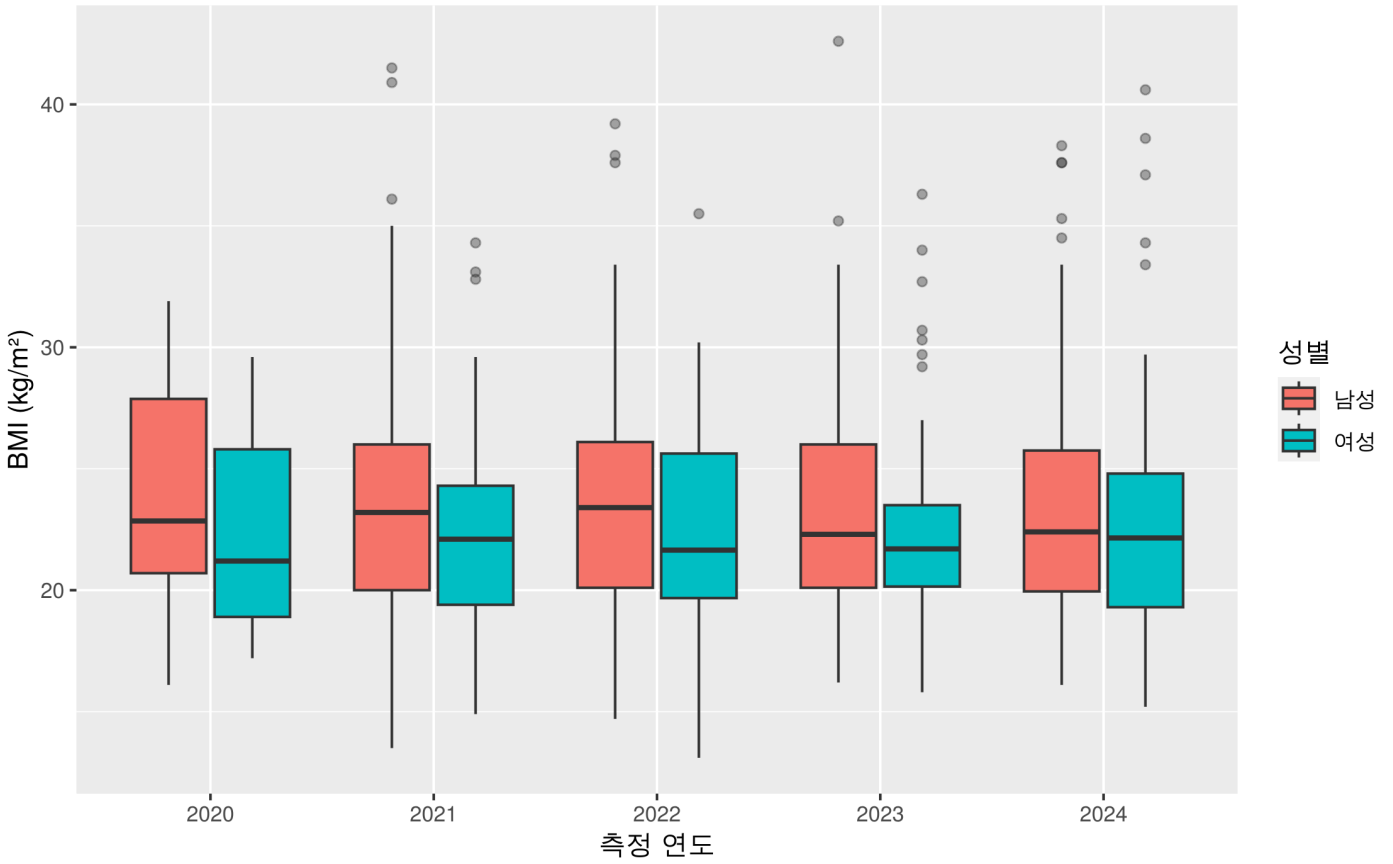


그림 4.6: 청소년의 연도별·성별 BMI 분포.

중앙값, 사분위범위, 수염 밖의 관측값을 비교합니다. 수염 밖의 점이 곧 입력 오류를 의미하지는 않습니다. 또 연도별 분포 차이를 동일한 사람의 변화로 해석하지 않습니다. 연도마다 측정 대상의 구성과 표본 수가 다를 수 있기 때문입니다. 여기서는 분포를 비교하며, 청소년 BMI에 성인 기준을 적용하여 건강 상태를 분류하지 않습니다.

4.4.3 상대악력과 윗몸말아올리기의 관계

실습 8. 두 변수가 함께 있는 `reg_data`로 산점도를 작성합니다. 성별 패널을 나누고 선형회귀 추세선을 추가합니다.

```
p_nfa_relation <- ggplot(reg_data, aes(x = grip_rel, y = curl_clean)) +
  geom_point(alpha = 0.45, color = "steelblue4") +
  geom_smooth(method = "lm", se = FALSE, color = "firebrick") +
  facet_wrap(~ sex) +
  labs(x = "상대악력 (%)", y = "윗몸말아올리기 (회)")
p_nfa_relation
```

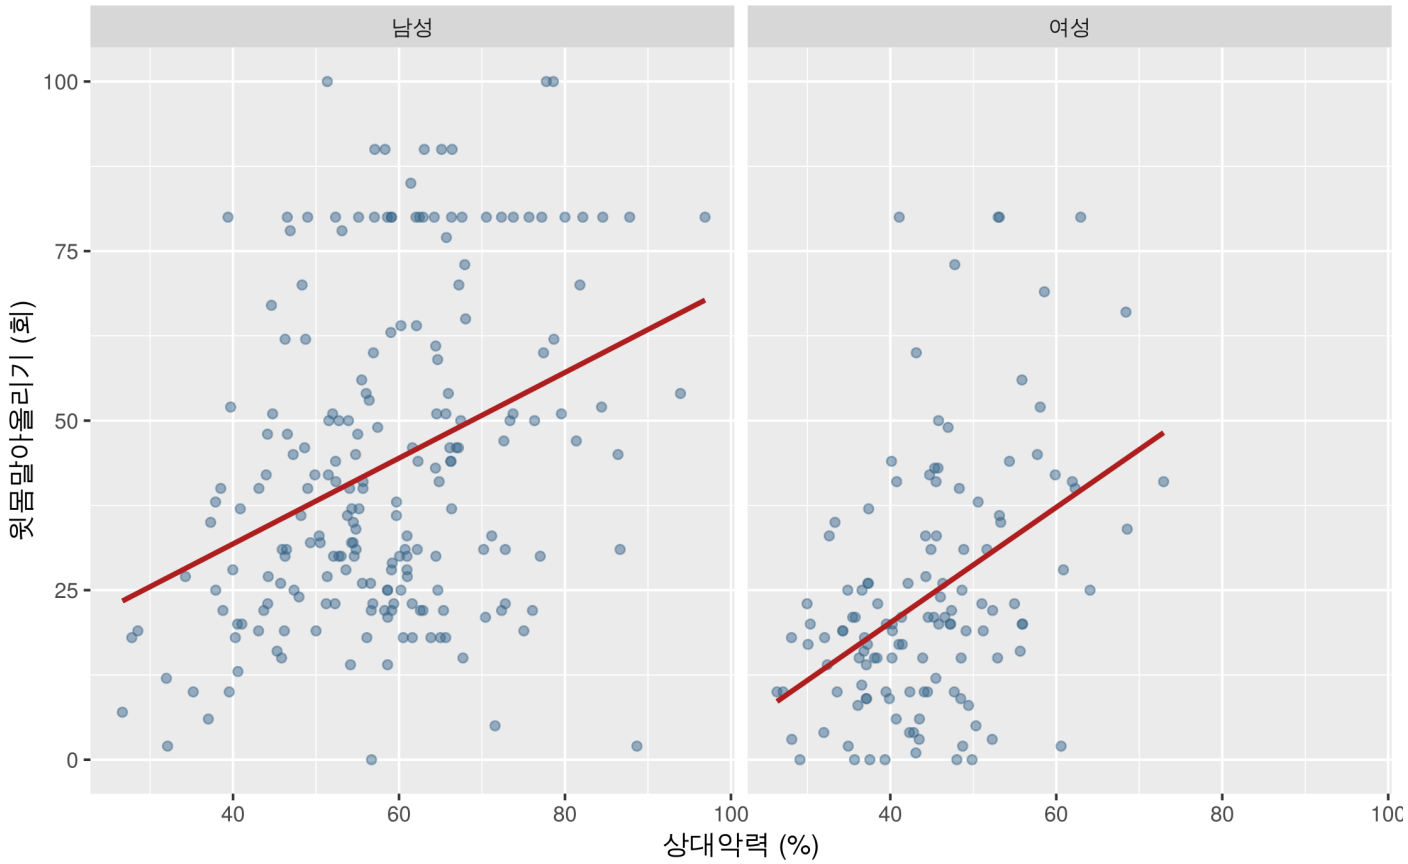


그림 4.7: 상대악력과 윗몸말아올리기의 관계. 성별로 다른 회귀직선을 적합했습니다.

전체 자료에 직선 하나를 그리면 집단 안의 관계와 집단 사이의 차이가 함께 반영됩니다. 먼저 패널별로 관계의 방향과 퍼짐을 확인합니다. 패널별 기울기가 달라 보인다는 사실만으로 그 차이가 통계적으로 확인되었다고 결론 내리지는 않습니다.

4.5 선형회귀분석과 예측

4.5.1 상관계수와 분석 대상

실습 9. 전체와 성별 상관계수를 구합니다. 이후 주 분석에서는 남성 청소년 자료만 사용하여 단순선형회귀모형을 적합합니다.

```
cor(reg_data$grip_rel, reg_data$curl_clean)
```

```
[1] 0.4901429
```

```
reg_data %>%
  group_by(sex) %>%
  summarise(n = n(), r = cor(grip_rel, curl_clean), .groups = "drop")
```

```
# A tibble: 2 × 3
  sex       n     r
  <fct> <int> <dbl>
1 남성    206 0.348
2 여성    126 0.433
```

```r
male_data <- reg_data %>% filter(sex == "남성")
range(male_data$grip_rel)
```

```
[1] 26.66667 96.88042
```

성별을 나누어 분석하면 서로 다른 성별 집단의 평균 차이가 하나의 기울기에 섞이는 것을 줄일 수 있습니다. 다만 같은 성별에서도 연령, 체격, 활동 수준 등 다른 요인은 남아 있습니다. 여기서는 앞 장에서 배운 단순선형회귀의 절차를 적용합니다.

4.5.2 모형 적합과 계수 해석

```r
fit_nfa <- lm(curl_clean ~ grip_rel, data = male_data)
summary(fit_nfa)
```

```
Call:
lm(formula = curl_clean ~ grip_rel, data = male_data)

Residuals:
    Min      1Q  Median      3Q     Max
-60.587 -16.090  -4.556  13.213  60.990

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   6.5474     7.1022   0.922    0.358
grip_rel      0.6320     0.1191   5.305 2.92e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 22.11 on 204 degrees of freedom
Multiple R-squared:  0.1212,    Adjusted R-squared:  0.1169
F-statistic: 28.15 on 1 and 204 DF,  p-value: 2.918e-07
```

```r
confint(fit_nfa)
```

```
                2.5 %     97.5 %
(Intercept) -7.4557118 20.5505657
grip_rel     0.3971184  0.8668517
```

회귀식의 반응변수는 윗몸말아올리기 횟수, 설명변수는 상대악력입니다. 이 자료에서 추정한 회귀식은 다음과 같습니다.

$$\widehat{\text{윗몸말아올리기}} = 6.547 + 0.632 \times \text{상대악력}$$

상대악력이 **1퍼센트포인트** 큰 경우, 모형이 추정한 윗몸말아올리기의 평균은 약 0.632회 많습니다. 10퍼센트포인트 차이로 해석하면 평균 차이는 약 6.32회입니다. 이를 악력 훈련의 효과로 해석하지 않습니다.

실습 10. 잔차에서 RMSE와 결정계수를 직접 계산하고, `summary()`의 값과 비교합니다.

```r
nfa_SSE <- sum(resid(fit_nfa)^2)
nfa_SST <- sum((male_data$curl_clean - mean(male_data$curl_clean))^2)
nfa_RMSE <- sqrt(mean(resid(fit_nfa)^2))
nfa_R2 <- 1 - nfa_SSE / nfa_SST

c(n = nrow(male_data), RMSE = nfa_RMSE, R_squared = nfa_R2)
```

```
           n         RMSE   R_squared
 206.0000000  22.0060817   0.1212473
```

```r
summary(fit_nfa)$r.squared
```

```
[1] 0.1212473
```

결정계수는 약 0.121으로, 이 분석 자료에서 관측된 윗몸말아올리기 변동의 약 12.1%를 회귀식이 설명합니다. RMSE는 약 22.01회입니다. 기울기가 양수여도 직선 주변의 퍼짐이 크면 개인별 예측의 불확실성이 큽니다. 이 값은 모형을 적합한 자료에서의 오차이며 새로운 자료에서 확인한 예측 성능은 아닙니다.

4.5.3 잔차 진단

실습 11. 적합값과 잔차의 관계, 표준화 잔차의 정규 Q-Q 그림을 확인하고 모형의 한계를 작성합니다.

```r
old_par <- par(mfrow = c(1, 2), mar = c(4.5, 4.5, 2, 1))
plot(fitted(fit_nfa), resid(fit_nfa), pch = 16, col = "steelblue",
     xlab = "적합값 (회)", ylab = "잔차 (회)")
abline(h = 0, lty = 2, col = "firebrick")
qqnorm(rstandard(fit_nfa), pch = 16, col = "steelblue", main = "",
       xlab = "이론적 분위수", ylab = "표준화 잔차")
qqline(rstandard(fit_nfa), col = "firebrick")
```

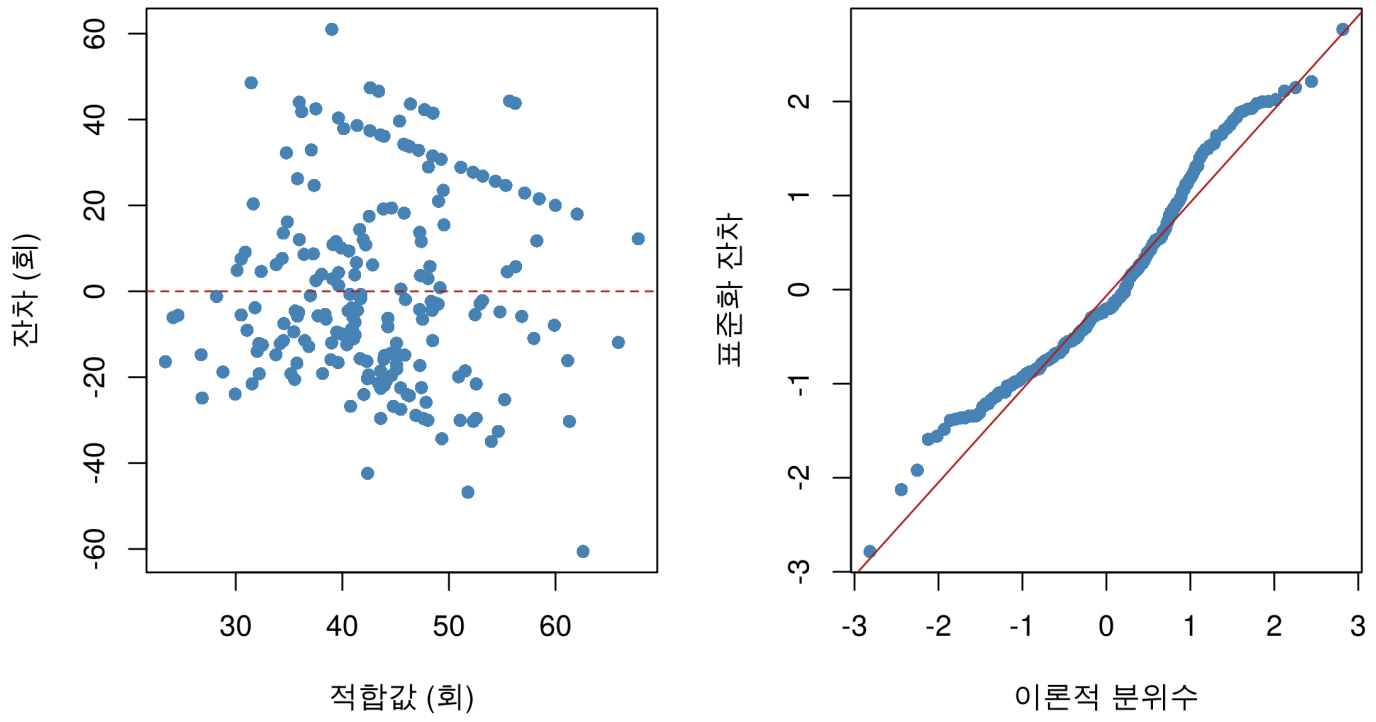


그림 4.8: 남성 청소년 모형의 잔차 진단. 왼쪽은 적합값과 잔차, 오른쪽은 정규 Q-Q 그림입니다.

```
par(old_par)
```

윗몸말아올리기는 음수가 될 수 없는 횟수 자료이며, 이번 주 분석은 설명서 범위인 0–100회로 한정되어 있습니다. 이런 자료에서는 오차의 정규성과 일정한 분산이라는 가정이 적절하지 않을 수 있습니다. 점들의 퍼짐과 꼬리의 이탈을 살펴보고, 단순선형회귀가 개인의 수행 횟수를 충분히 표현하는지 검토합니다.

4.5.4 점예측과 구간 예측

실습 12. 상대악력이 50%인 남성 청소년의 평균반응 신뢰구간과 새로운 개인의 예측구간을 구합니다.

```
new_nfa <- data.frame(grip_rel = 50)
nfa_mean_ci <- predict(fit_nfa, newdata = new_nfa, interval = "confidence")
nfa_individual_pi <- predict(fit_nfa, newdata = new_nfa, interval = "prediction")
nfa_mean_ci
```

```
       fit     lwr      upr
1 38.14668 34.5496 41.74376
```

```
nfa_individual_pi
```

```
       fit       lwr      upr
1 38.14668 -5.602151 81.89551
```

점예측값은 약 38.15회입니다. 평균의 예측이므로 정수가 아닐 수 있습니다. 개인의 95% 예측구간은 약 -5.6회에서 81.9회입니다. **음수인 하한은 실제로 가능한 수행 횟수가 아닙니다.** 이는 정규오차를 전제한 선형모형의 예측구간을 횟수 자료에 그대로 적용할

때의 한계를 보여 줍니다. 하한만 임의로 0으로 바꾸어 동일한 95% 예측구간이라고 보고하지 않습니다.

50%는 이 분석 자료의 설명변수 범위 안에 있지만, 범위 안에서 예측했다는 이유만으로 모형의 적절성이 보장되지는 않습니다. 자료의 범위, 잔차의 특성과 예측구간을 함께 확인해야 합니다.

4.6 종합 과제와 분석 보고서

4.6.1 과제 1 · 요약통계와 분포 비교

여성 청소년 자료에서 신장과 체중의 평균, 표준편차, 변동계수를 구합니다. 어느 변수가 평균 대비 상대적 산포가 큰지 설명하고, 두 변수의 단위가 다른 상황에서 표준편차만 비교하면 어떤 문제가 있는지 작성합니다.

4.6.2 과제 2 · 도수와 비율 그래프

연도별 성별 **비율**을 나타내는 누적 막대그래프를 작성합니다. 앞에서 작성한 도수 그래프와 비교하여, 각 그래프가 어떤 질문에 답하는지 설명합니다.

4.6.3 과제 3 · 여성 청소년의 회귀모형

여성 청소년의 상대악력으로 윗몸말아올리기를 설명하는 단순선형회귀모형을 적합합니다. 표본 수, 기울기, 결정계수, RMSE를 구하고 남성 모형과 비교합니다. 다른 집단의 결정계수 차이를 곧바로 예측 능력의 우열로 해석할 수 있는지도 검토합니다.

4.6.4 과제 4 · 범위 점검의 영향을 비교하기

주 분석에서 제외한 윗몸말아올리기 120회 기록을 포함하여 남성 모형을 다시 적합합니다. 분석 결과가 값의 처리 방식에 얼마나 민감한지 비교하고, 보고서에 기록해야 할 사항을 작성합니다.

4.6.5 보고서 작성과 결과 저장

다음 요소를 포함하여 1–2쪽 분량의 분석 보고서를 작성합니다.

1. **자료와 분석 대상:** 자료의 출처, 연령 조건, 측정 기간, 분석 기록 수를 제시합니다.
2. **자료 처리:** 결측값과 범위 밖 값의 처리, 상대악력 계산 방법을 설명합니다.
3. **기술통계와 시각화:** 요약표 1개, 분포 그림 1개, 관계 그림 1개를 제시하고 단위와 분모를 명시합니다.
4. **회귀분석:** 회귀식, 기울기의 해석, 결정계수와 RMSE, 잔차 진단을 제시합니다.
5. **예측과 한계:** 점예측과 구간을 구분하고, 횟수 자료에 선형모형을 적용한 한계와 표본의 적용 범위를 서술합니다.

다음은 주 분석 결과를 정리한 문장 예시입니다.

> 제공된 2,000건의 측정 기록 중 13–18세 청소년 847건을 선정하였다. 상대악력과 범위 점검을 통과한 윗몸말아올리기 값이 모두 있는 남성 청소년 206건으로 단순선형회귀분석을 수행하였다. 상대악력이 10퍼센트포인트 큰 경우 추정한 평균 수행 횟수는 약 6.32회 많았다. 결정계수는 0.121, 적합 자료의 RMSE는 22.01회였다. 양의 관계가 관찰되었으나 개인별 퍼짐이 크고 예측구간에 음수가 포함되어, 이 모형만으로 개인의 수행 횟수를 예측하는 데 한계가 있다. 이 관계를 훈련 효과나 전체 청소년의 특성으로 일반화하지 않았다.

필요한 경우 요약표와 그래프를 저장합니다. 다음 코드는 직접 실행할 때에만 파일을 생성합니다.

```
dir.create("outputs", showWarnings = FALSE)
write.csv(grip_summary, "outputs/sports100-summary.csv",
          row.names = FALSE, fileEncoding = "UTF-8")
ggsave("outputs/sports100-relation.png", plot = p_nfa_relation,
       width = 9, height = 5, dpi = 300)
```

4.6.6 참고 자료와 실습 파일

이 장은 제공된 `train_R.qmd`의 5장과 함께 제공된 측정·변수 설명 파일을 이용하여 작성했습니다. 원본의 가상 등급 기준 파일인 `class_level.xlsx`는 이번 실습에 사용하지 않습니다. 이 장의 범위는 기술통계, 시각화와 단순선형회귀분석의 종합 적용입니다.

- 4장 R Markdown 원고
- 4장 R 실습 코드
- 측정 자료 CSV
- 변수 설명 CSV

파일을 개별로 내려받는 경우 두 CSV는 실행 파일이 있는 폴더의 `data` 하위 폴더에 저장합니다. 코드는 이 장의 처음부터 순서대로 실행하며, 앞 장에서 만든 객체 없이도 실행할 수 있도록 구성했습니다.